Tutorial de expresiones regulares: Manipulación de cadenas de texto

Pablo Ruiz Fabo

Université de Strasbourg – Laboratoire LiLPa

Público previsto

- Un público no técnico, como humanistas que quieren aprender a manipular cadenas de texto de forma eficaz en un editor de texto o en otra aplicación que soporte expresiones regulares.

Plan del tutorial

- I: “Teoría”, en estas diapositivas
- II: Ejercicios, en un directorio aparte

Un archivo de texto llamado `ejemplos.txt` permite aplicar los ejemplos de cada diapositiva

Introducción

Expresiones regulares (Regex)

- Herramienta (o “lenguaje”) para encontrar y modificar cadenas de texto que correspondan a un patrón de caracteres
  - palabras con un sufijo determinado
  - rimas
  - palabras que empiezan con un prefijo dado
  - fechas
  - sílabas …
- Una expresión regular puede representar múltiples cadenas de texto

Sitios y editores para probar las regex

Sitios

- regexpal.com
- regex101.com
- regexr.com

Editores

- Geany (usado en estas slides) [multiplataforma]
- Sublime Text [multiplataforma]
- Notepad++ [Windows]

Variedades de regex

- Existen muchas variedades de regex.
  - Simples, más antiguas:
    - Regex básicas
    - Regex extendidas
- Variedades usadas en esta clase:
  - Librerías actuales, similares a PCRE (Perl-compatible regular expressions)

Elementos del lenguaje

Veremos esto con más detalle después …

- **Literales**: en general, un carácter se corresponde a sí mismo
- **Caracteres especiales**: Representan conjuntos de caracteres o llevan a cabo ciertas funciones
  - **Abreviaturas de clase** de caracteres
  - **Operadores** y **cuantificadores**: modifican la forma en que se buscan las correspondencias (p. ej. número máximo de correspondencias a encontrar)
  - **Anclas (anchors)**: especifican una posición, como el principio o el final de la línea

Editor Geany:
Búsqueda de patrones

Ctrl + F

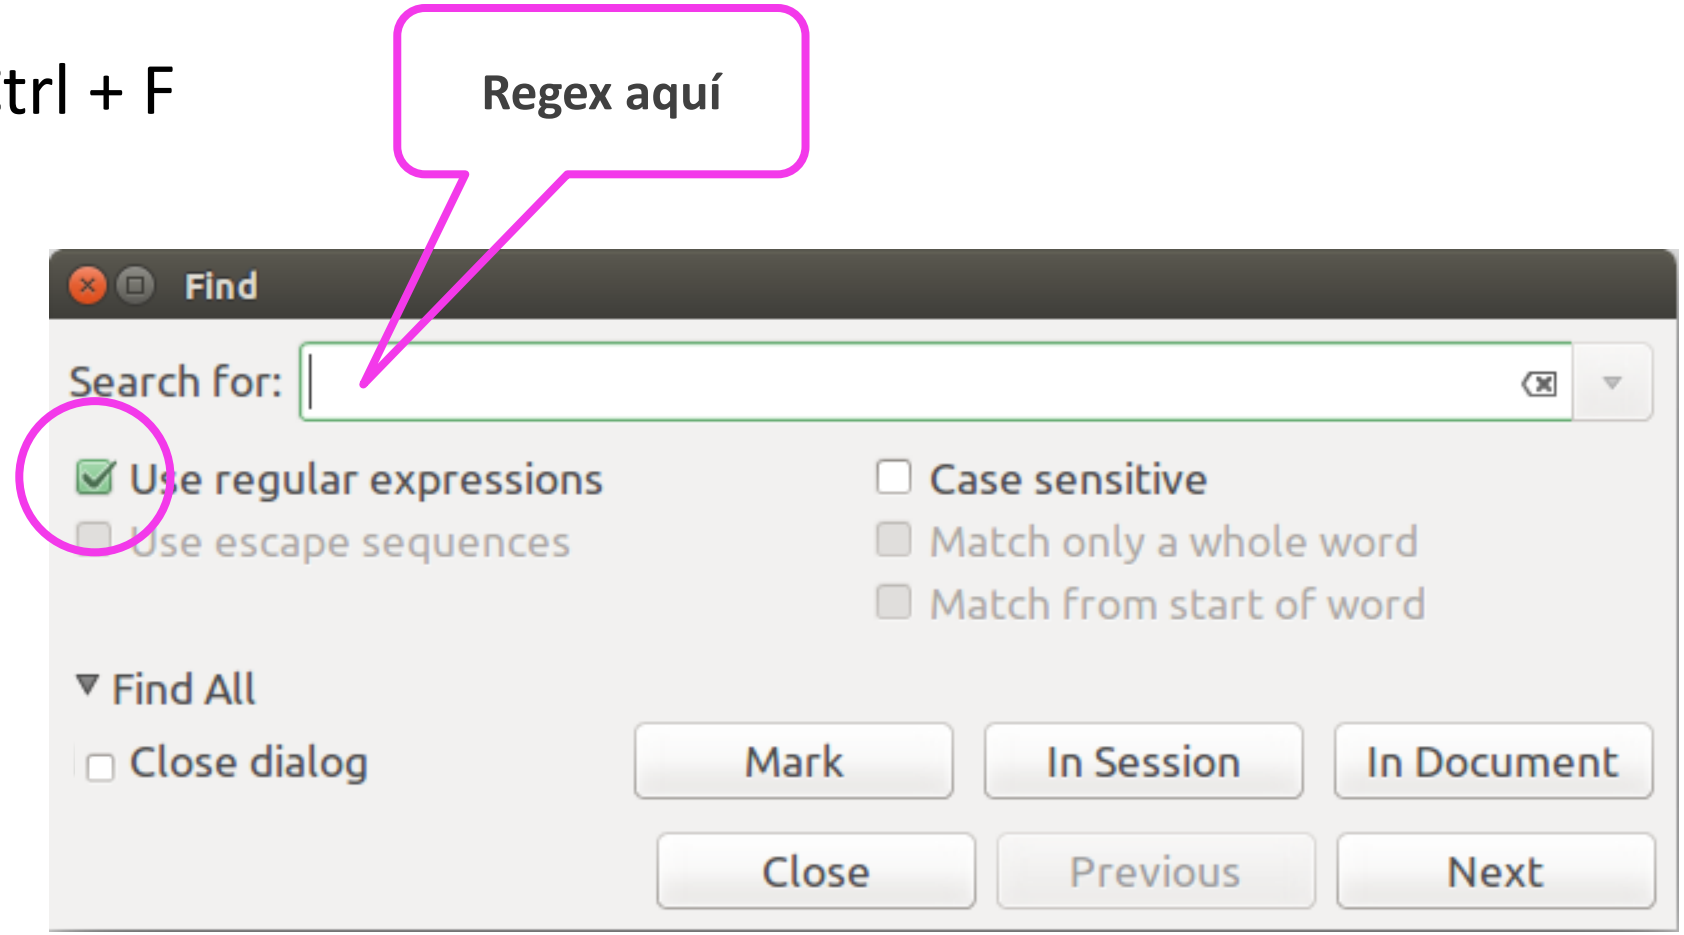

Editor Geany:
Búsqueda de patrones

Ctrl + F

Literales

Literales: En general, un carácter se corresponde a sí mismo

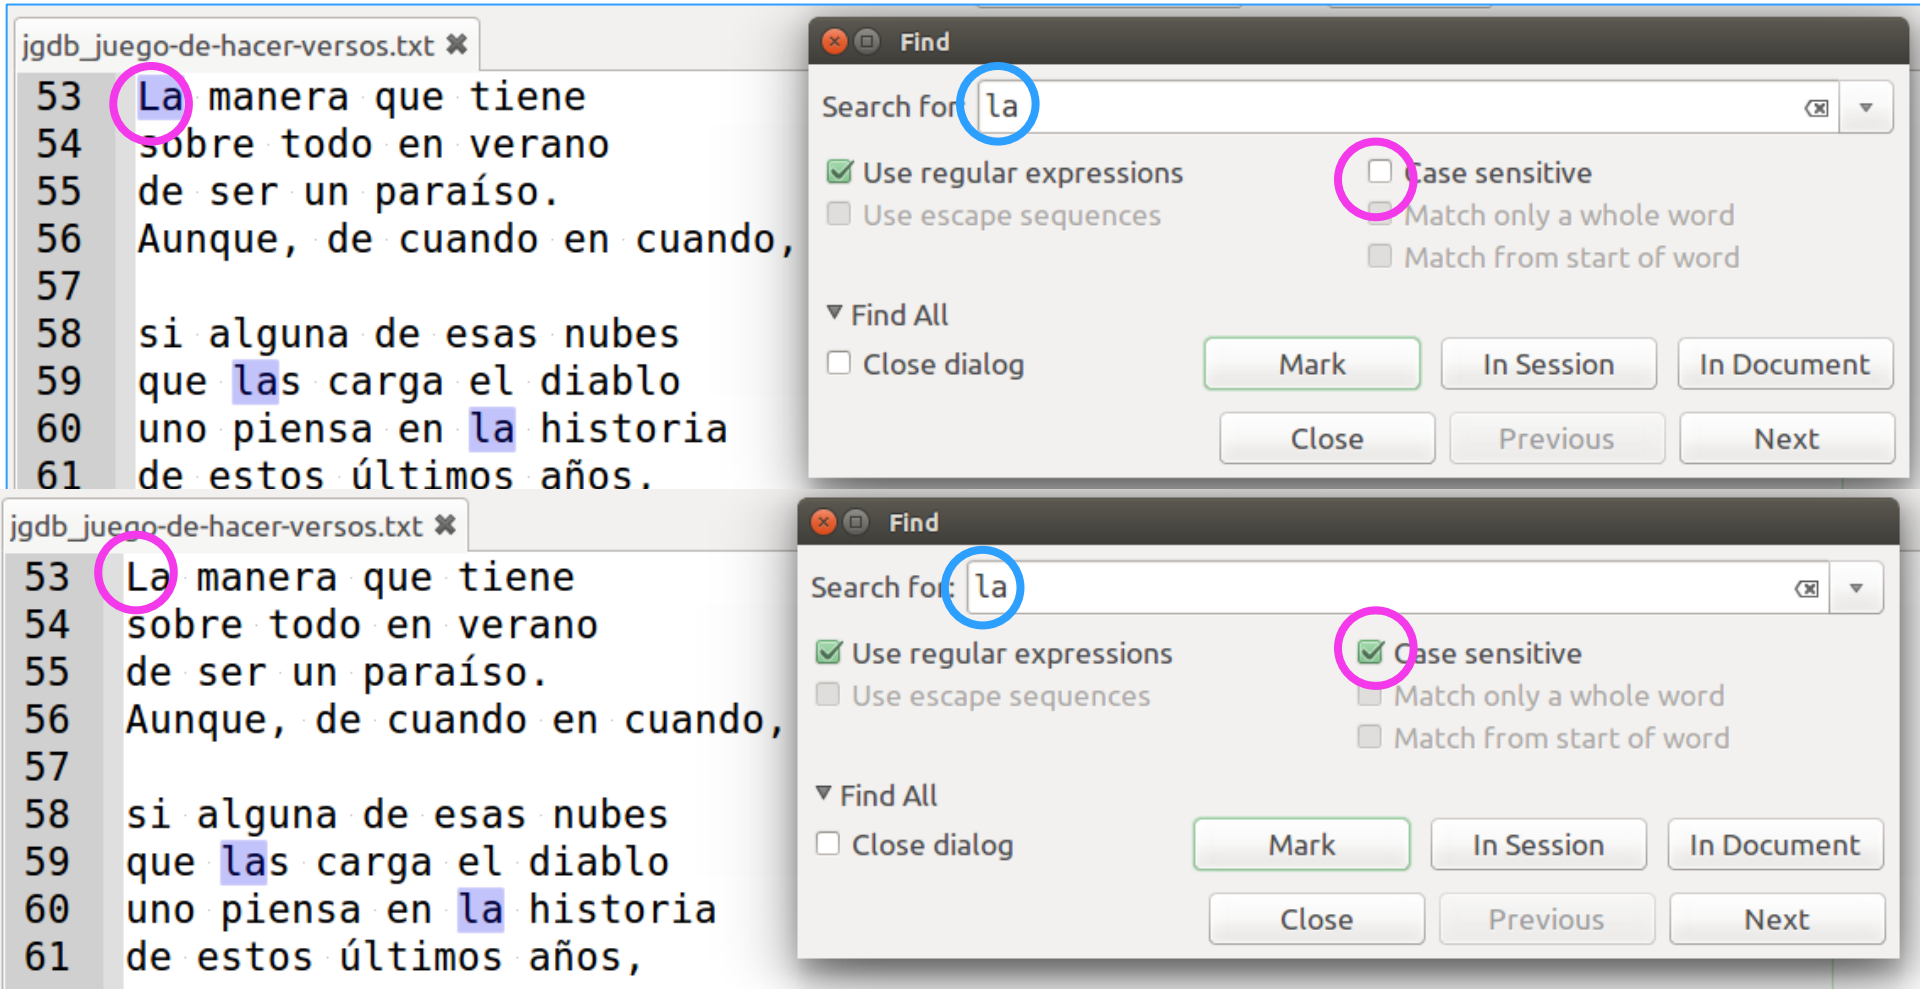

Cuantificadores

Cuantificadores

- Funciones más avanzadas
- Veremos ejemplos más adelante
- Cuantificadores
  - cuántas veces queremos reconocer una expresión (slides siguientes)
- Modos de cuantificación
  - buscar la cadena mínima o la máxima que corresponda a la expresión (Slide 24)

Cuantificador *?* : 0 o 1 ocurrencia

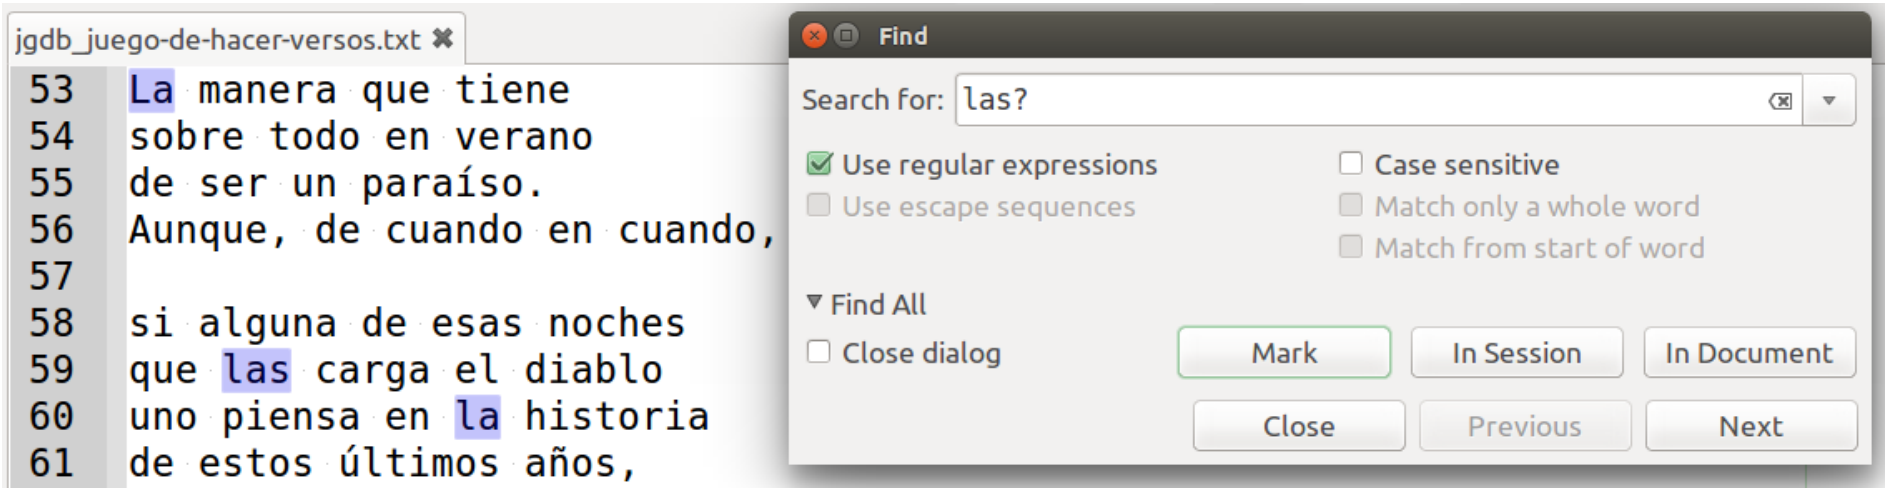

las? corresponde a ***la*** y ***las***

Cuantificador + : 1 o más veces

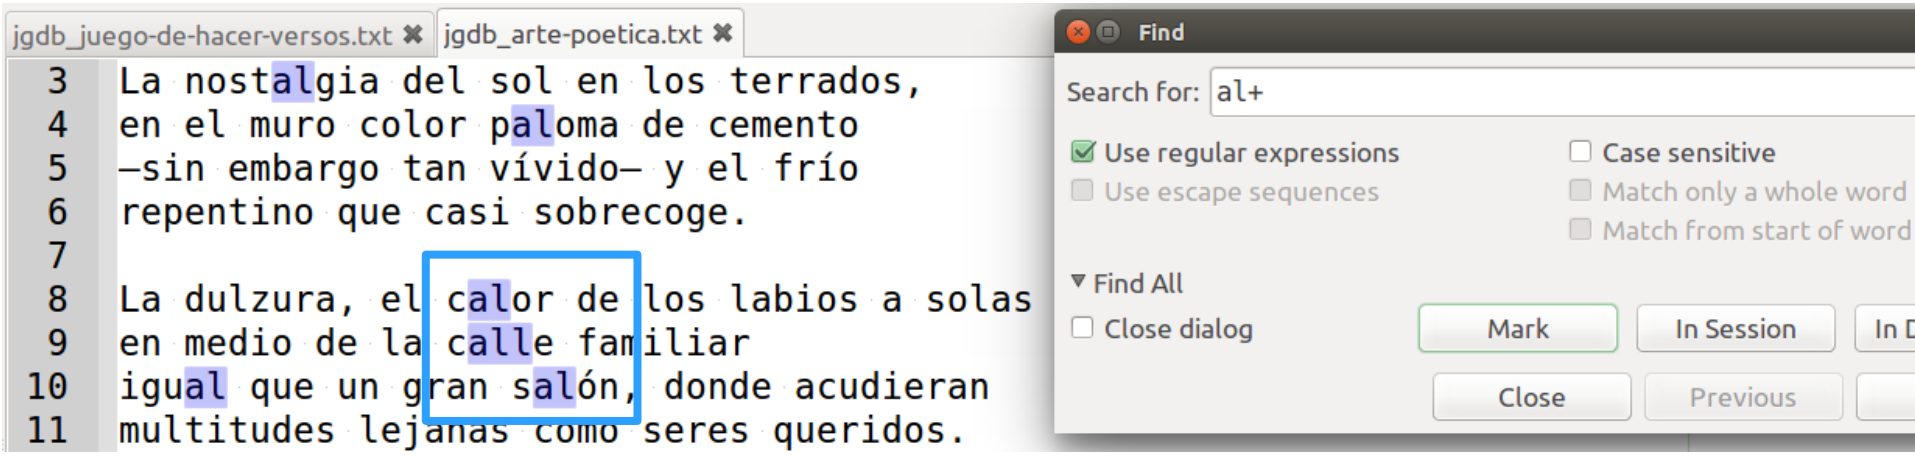

al+ corresponde a ***al*** y ***all***, y también ***allllllll*** … (para cualquier número de *l*)

{x}: exactamente *x* veces

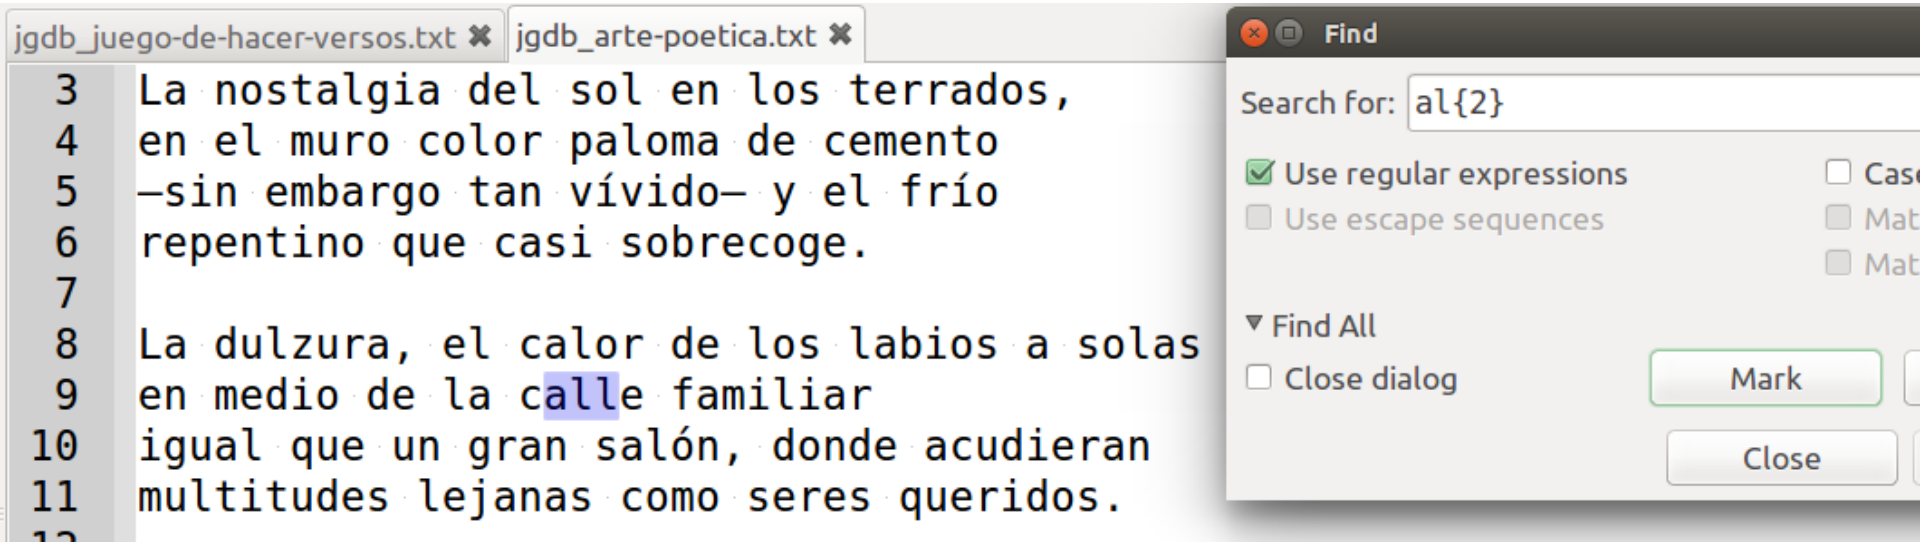

al{2} corresponde a ***all***

{x}: exactamente *x* veces

- ¿Cómo encontrar *alal*?

{x}: exactamente *x* veces

- ¿Cómo encontrar *alal*?

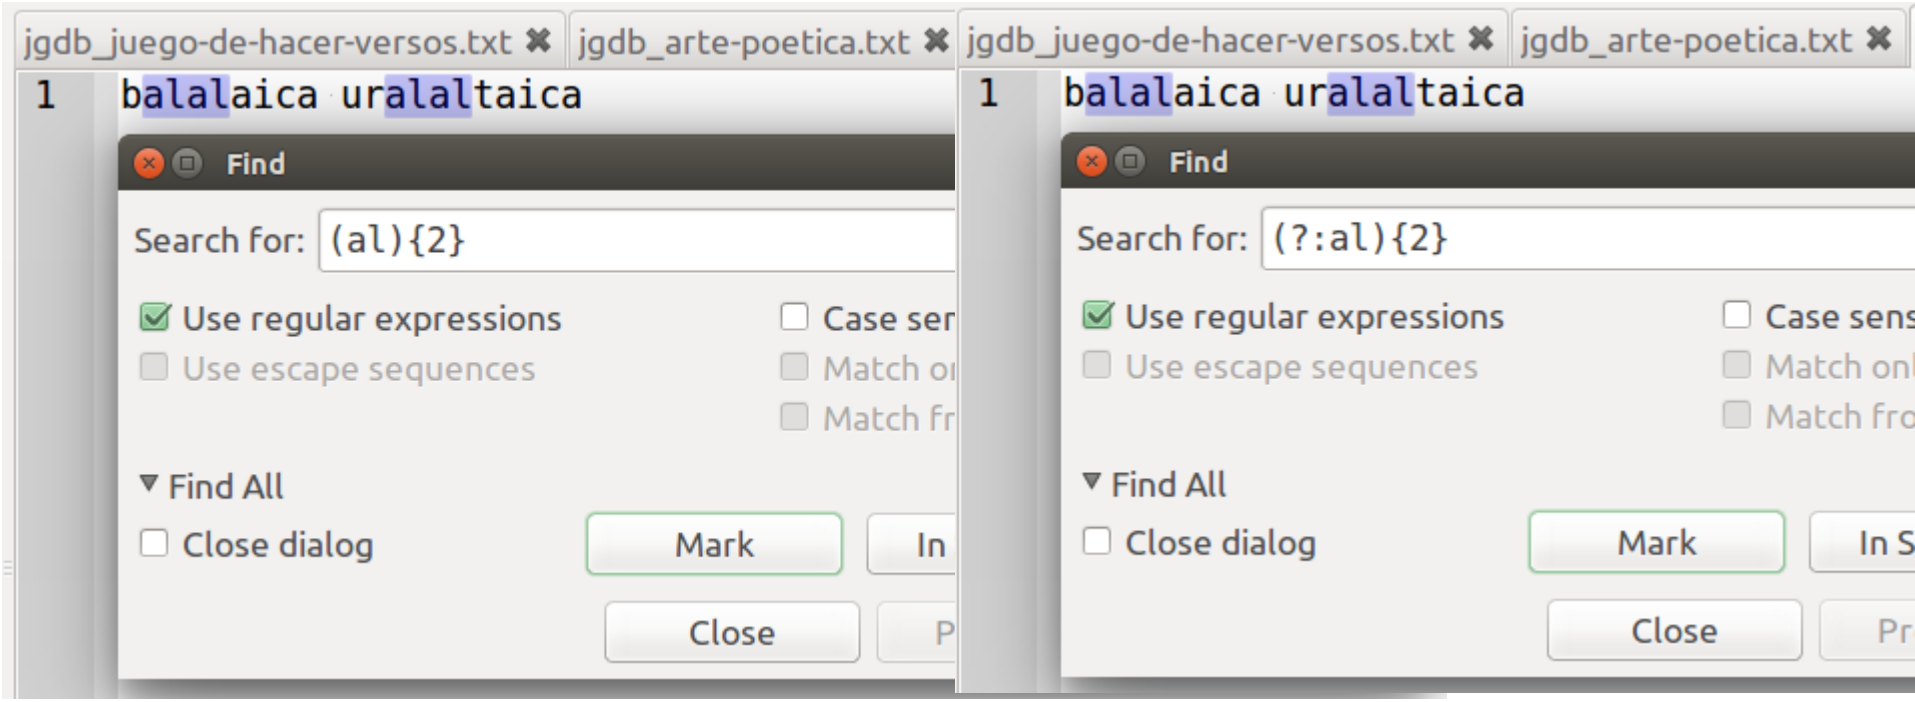

- Tanto `(al){2}` como `(?:al){2}` valen …
  (ver slide 60 para la diferencia)

{x,y} : Entre *x* e *y* veces

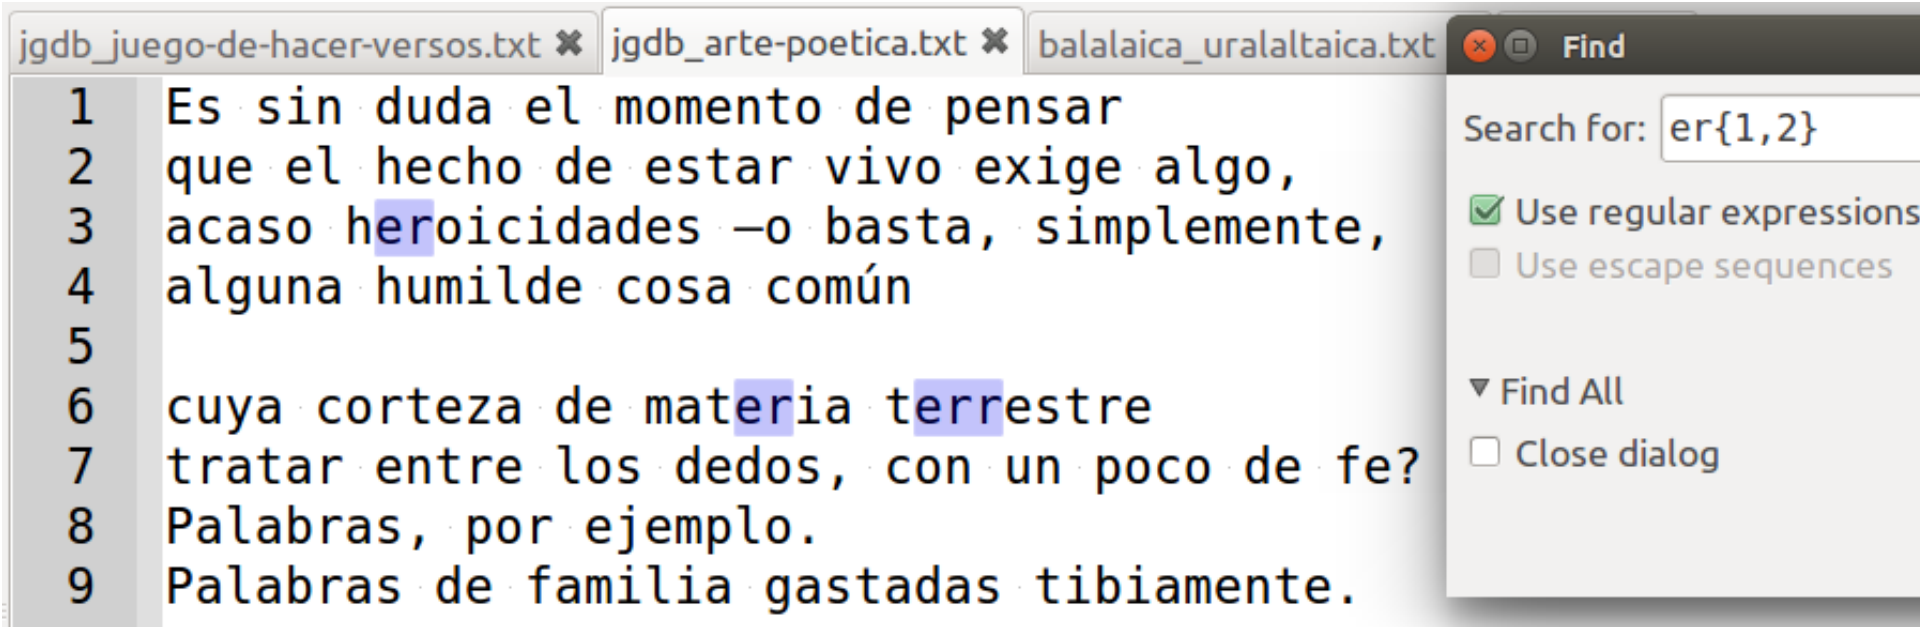

er{1,2} corresponde a ***er*** y ***err***

{x,y} : Between *x* and *y* times

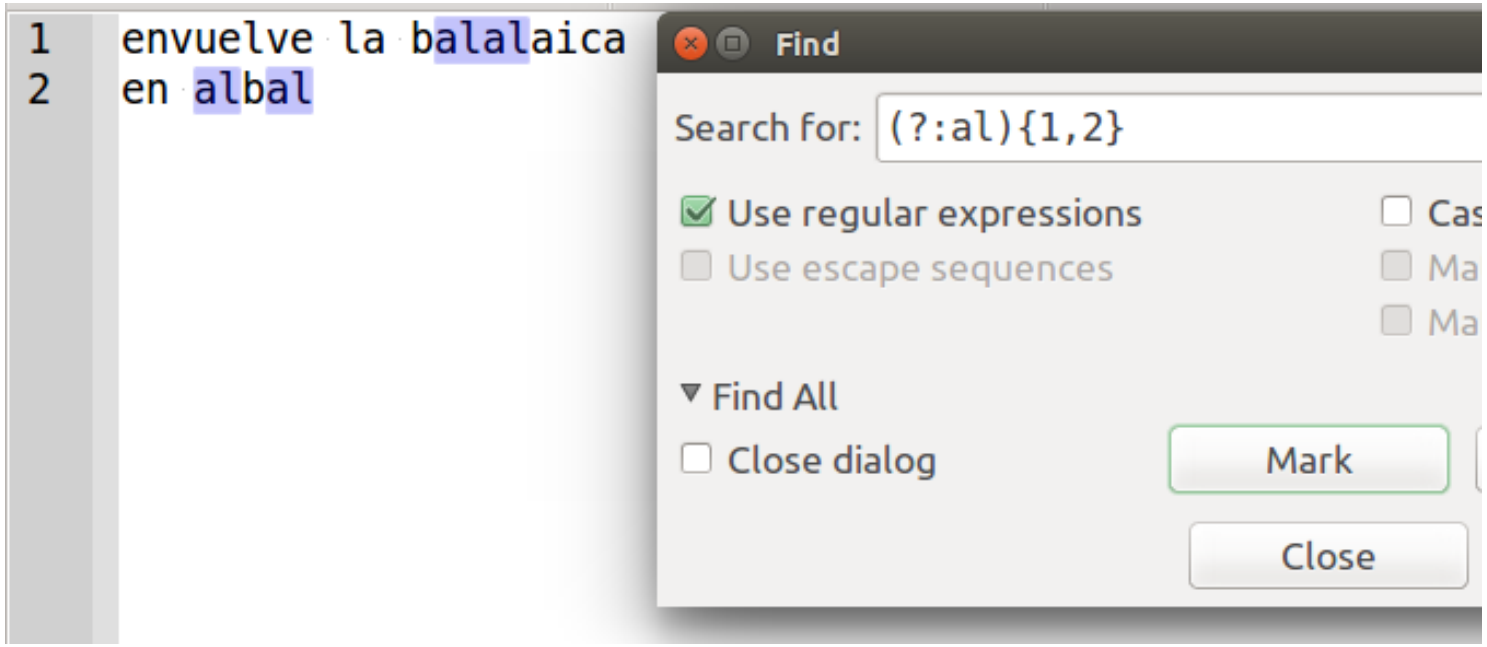

(?:al){1,2} corresponde a ***al*** y ***alal***

{x,y} : Entre *x* e *y* veces

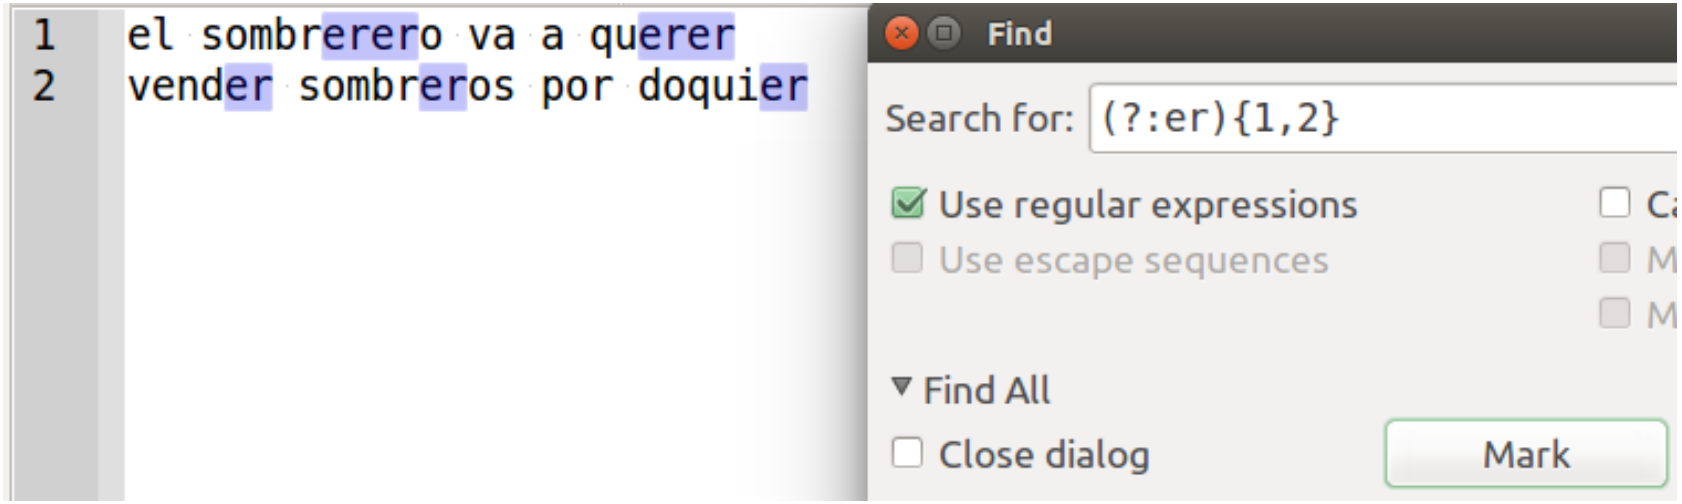

(?:er){1,2} corresponde a ***er*** y ***erer***

* : 0 o más veces

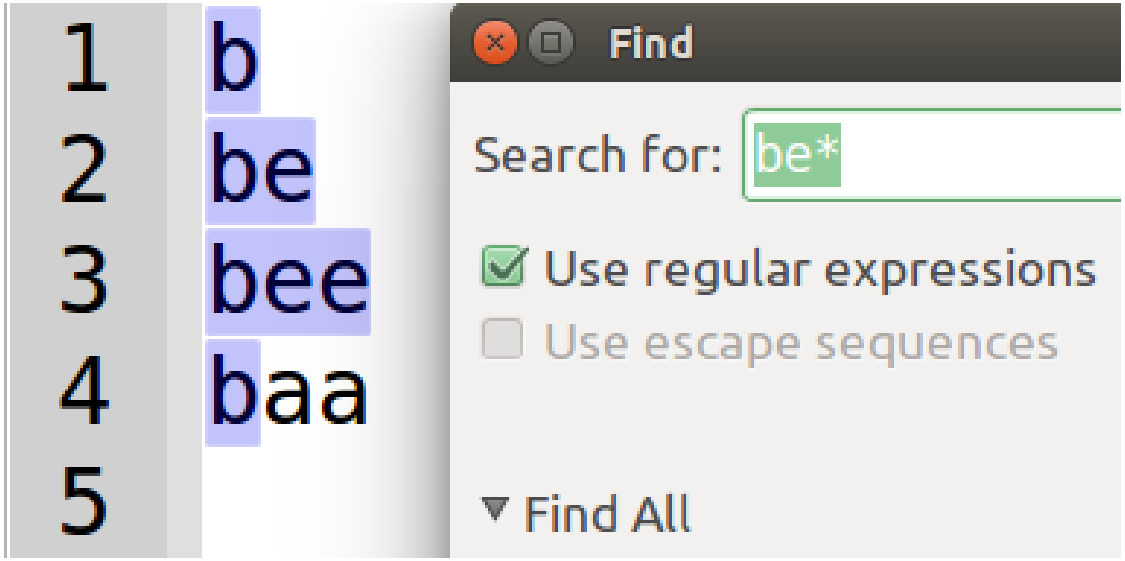

be* corresponde a ***b***, y a ***b*** seguida de todo número de ***e***

Modos de cuantificación para + y * : Greedy vs. Lazy

- **Greedy**: No parar hasta la última correspondencia posible (modo por defecto)

Fuente : I. Taylar, CC-BY

Modos de cuantificación para + y * : Greedy vs. Lazy

- **Lazy**: Parar en la correspondencia mínima posible

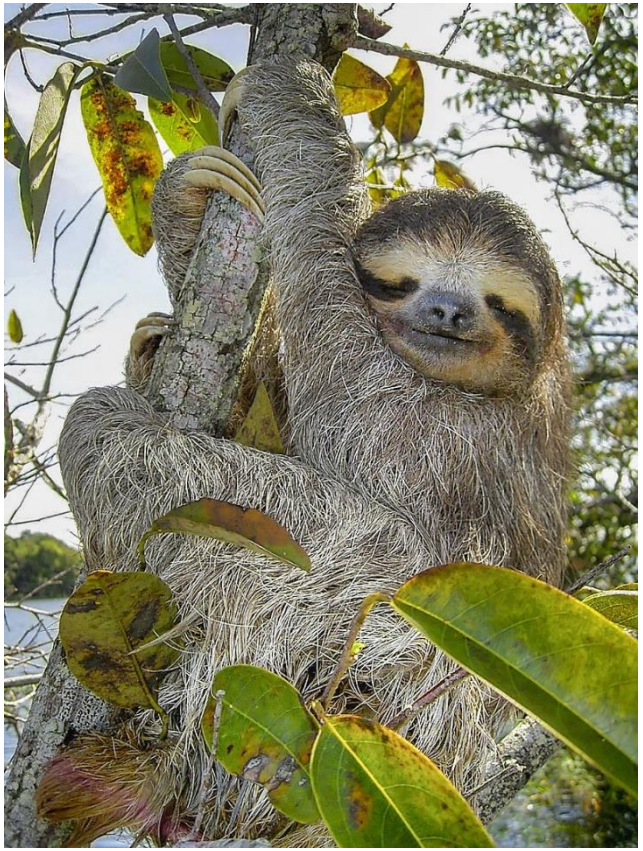

Fuente, por S. Laube (dominio público)

Matching modes for + and *: Greedy vs. Lazy

- **Greedy**: Parar en la última correspondencia posible **(modo por defecto)**
- **Lazy**: Parar en la primera correspondencia posible
- Para hacer que el cuantificador esté en modo lazy, añadir un signo de interrogación:
  - Greedy: **+** *****
  - Lazy: **+?** ***?**

Modos de cuantificación para + y * : Greedy vs. Lazy

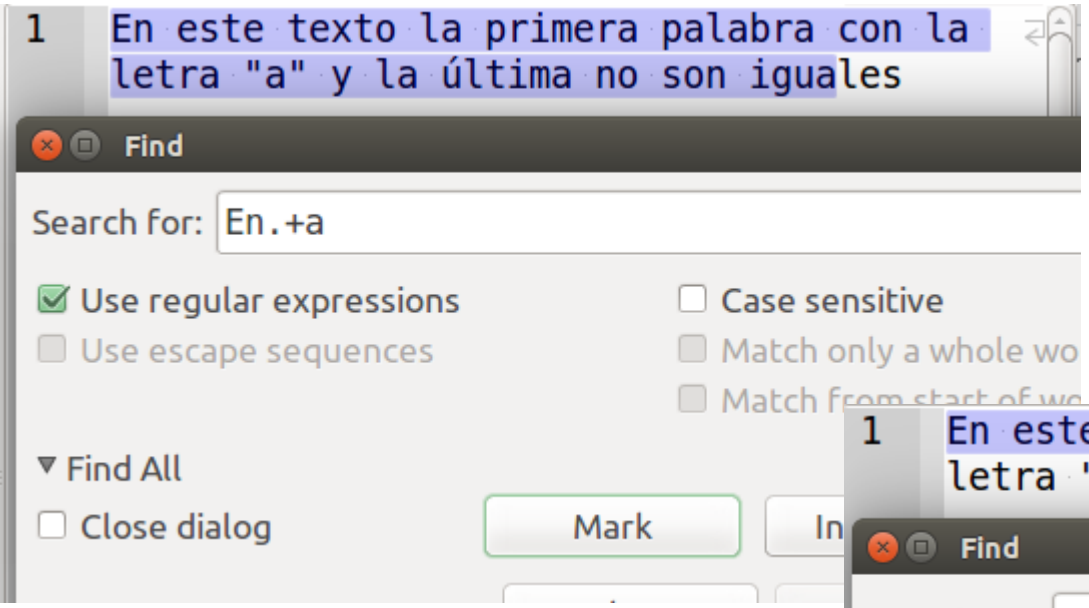

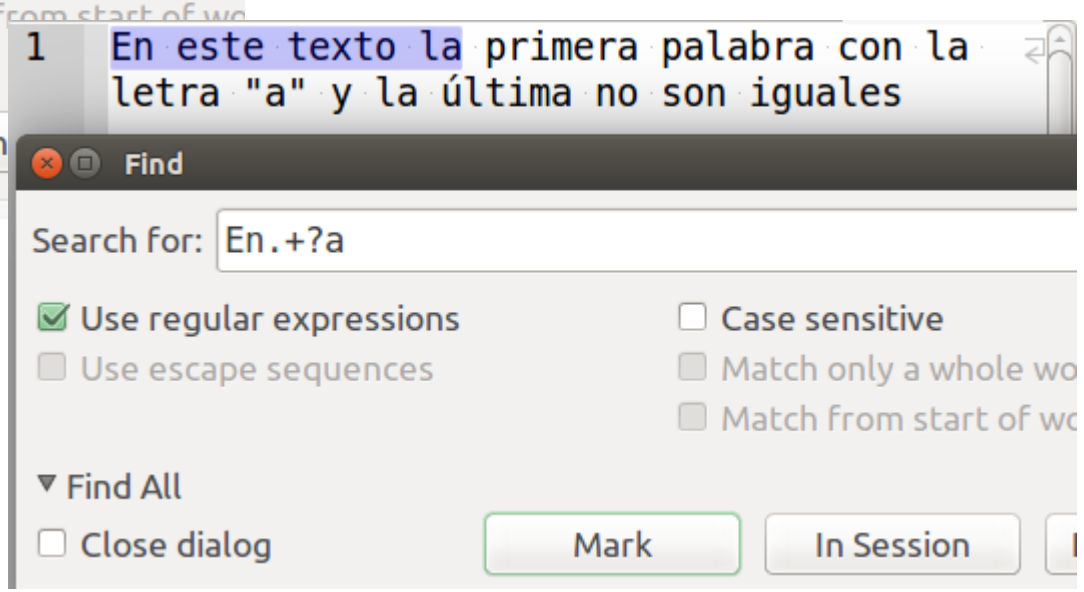

Modos de cuantificación para + y * : Greedy vs. Lazy

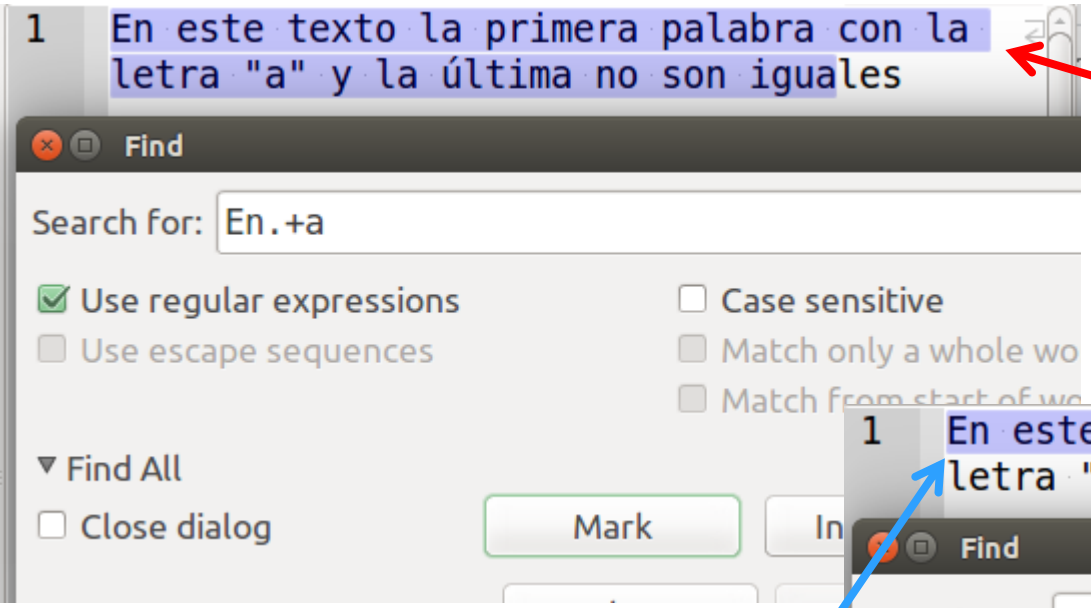

Greedy: Cubre desde `En` hasta la última ocurrencia de la letra `a`; sigue aceptando caracteres mientras quede una *a* más a la derecha en lacadena

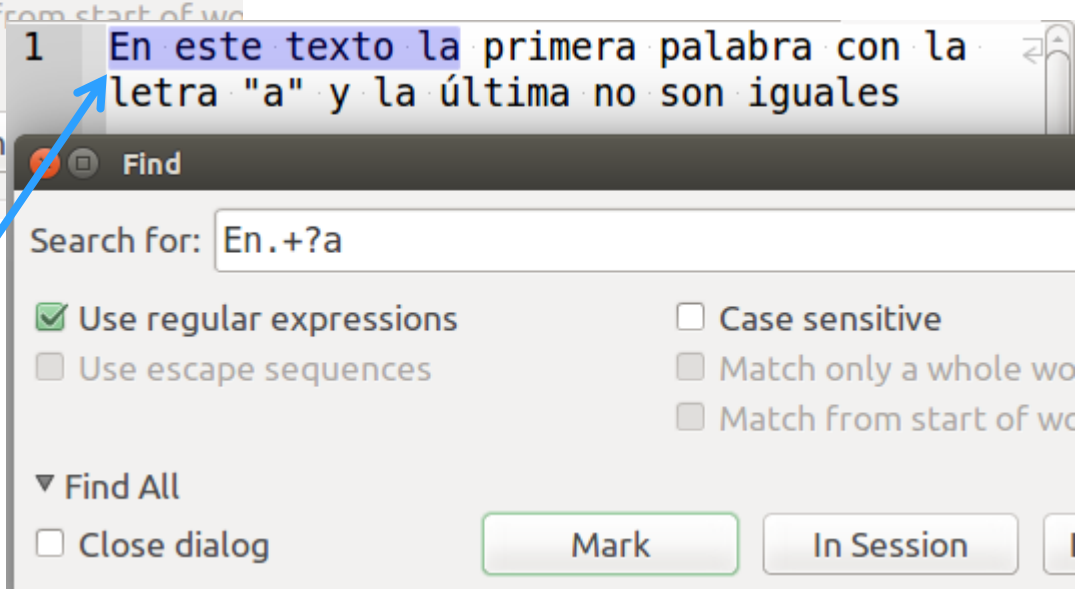

Lazy: Cubre desde `En` hasta la primera ocurrencia de la letra `a`; deja de aceptar caracteres en cuanto encuentra una *a*

Cuantificadores: Resumen

Cuantificador	Comportamiento
x?	x es opcional (0 or 1 ocurrencias)
x*	x es opcional (0 o cualquier número de ocurrencias)
x+	x ocurre al menos una vez
x{y}	x ocurre y veces exactamente
x{w,z}	x ocurre entre w veces y z veces
*? +?	El signo ? hace que el cuantificador se comporte de modo lazy
(?:xxx) (Nota: esto no es un cuantificador)	Para hacer que el cuantificador tenga alcance sobre una secuencia de más de un carácter, poner la secuencia dentro de (?:) y añadir el cuantificador tras el paréntesis de cierre

Escapar Caracteres

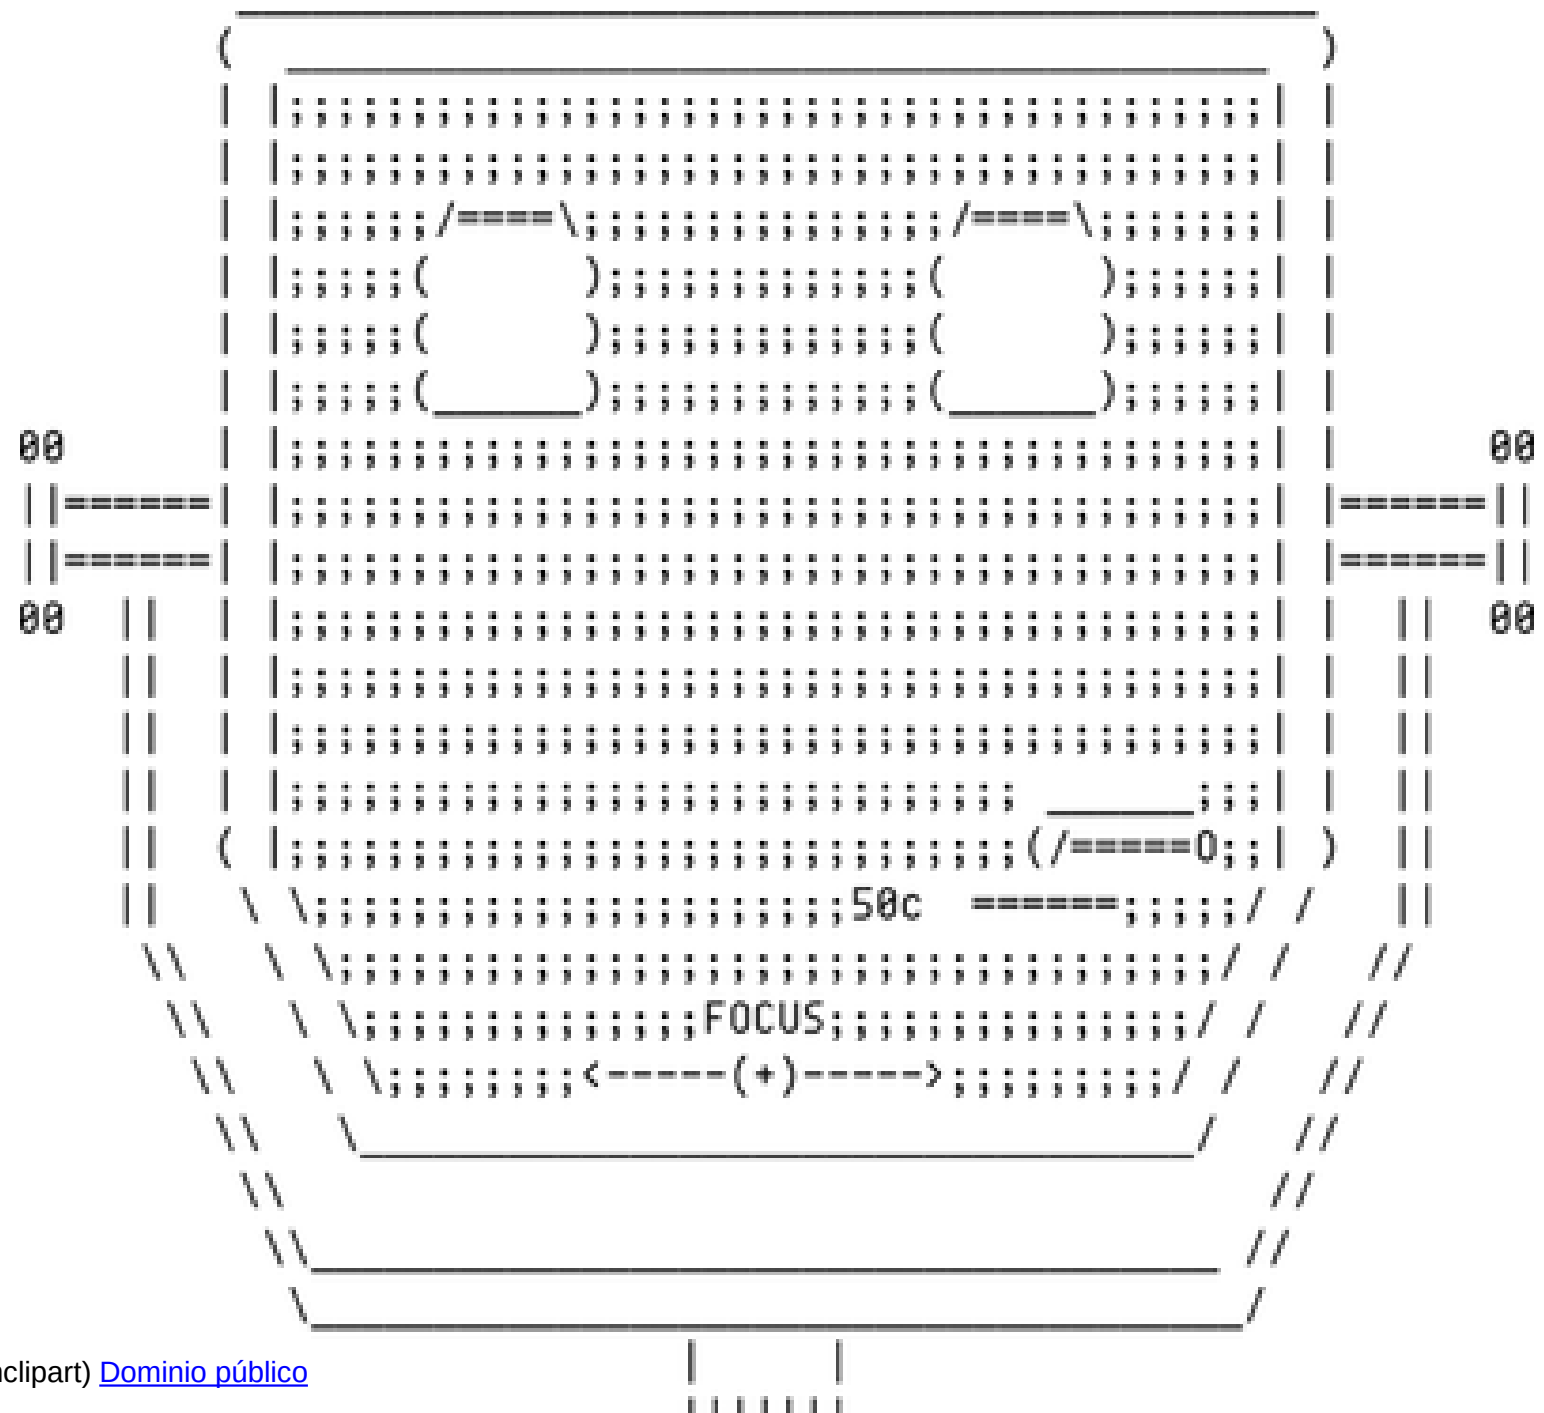

[Fuente](#) (openclipart) [Dominio público](#)

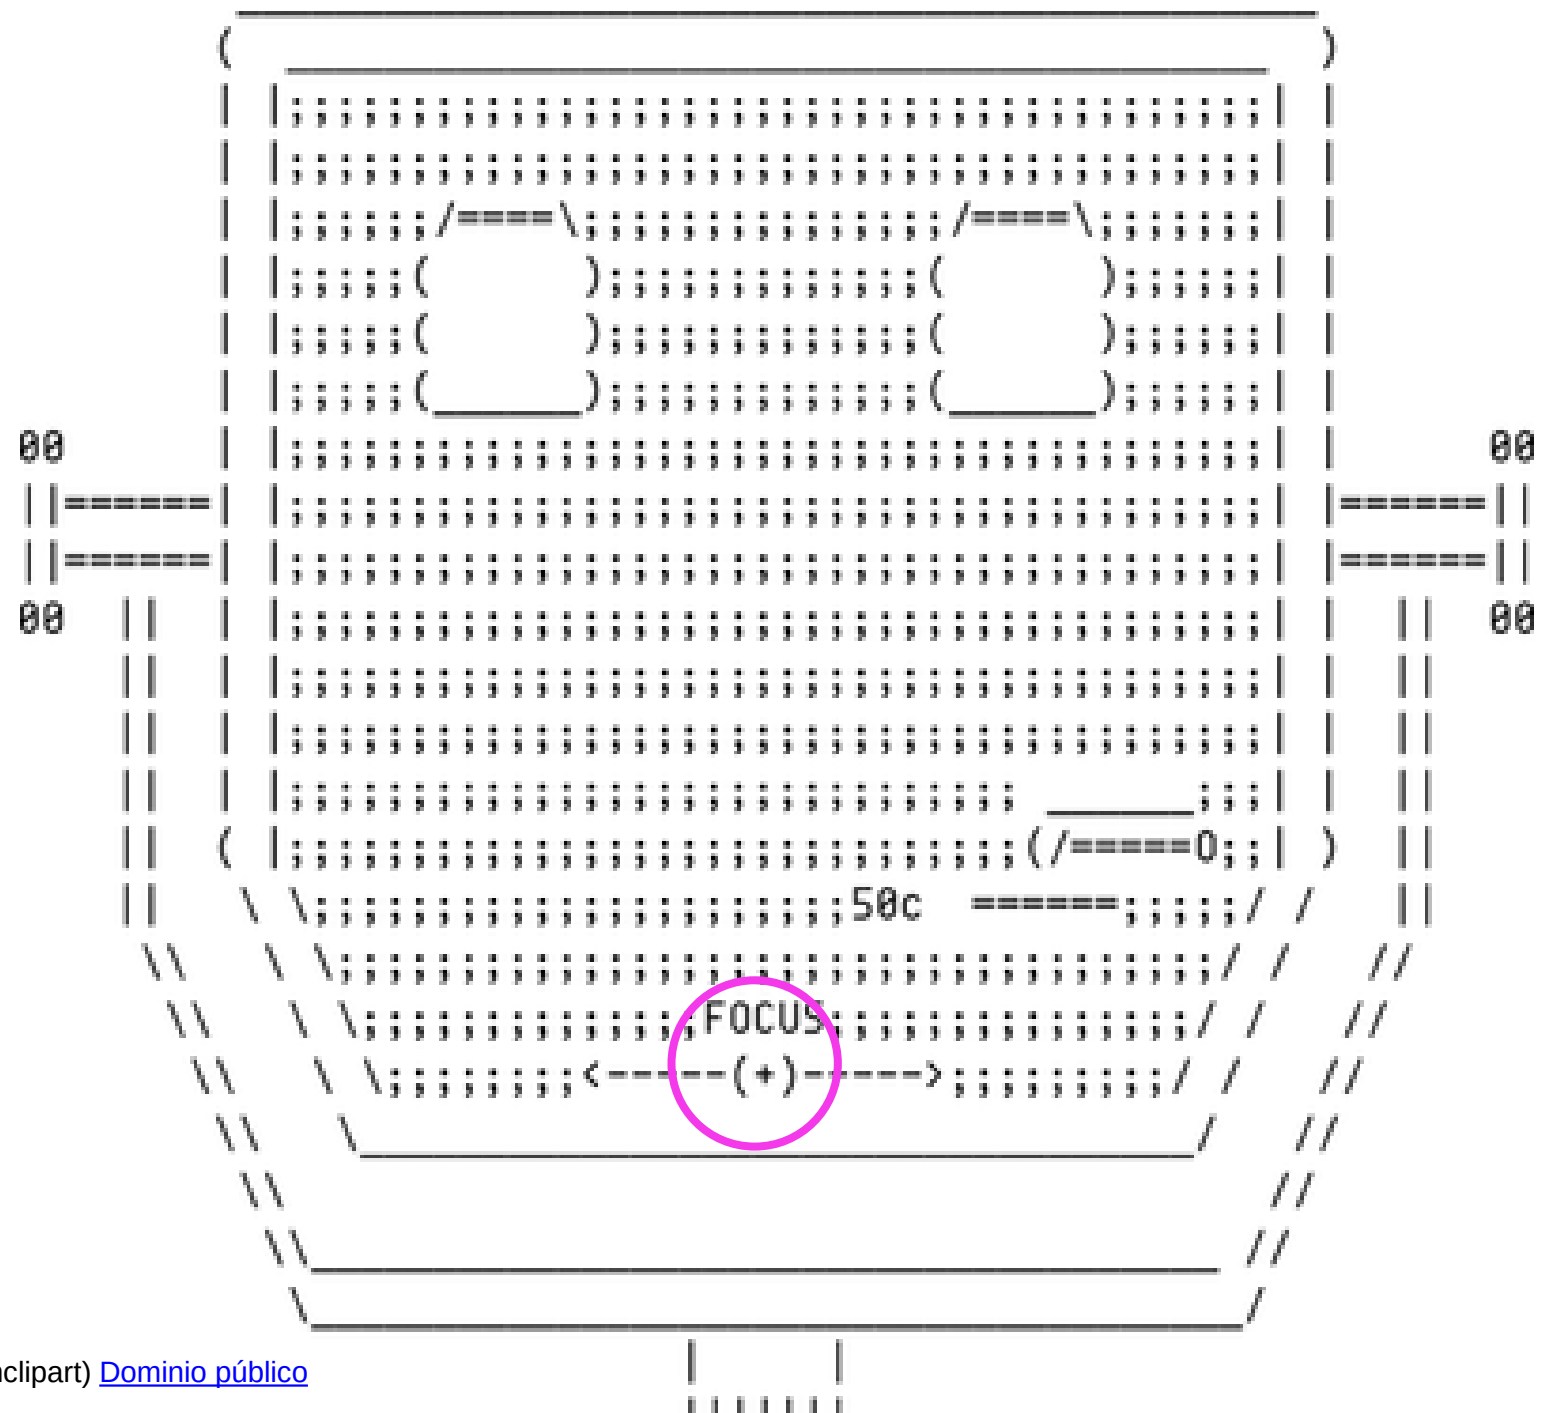

[Fuente](#) (openclipart) [Dominio público](#)

Encontrar caracteres especiales

- ¿Cómo encontrar caracteres especiales?
- Deben ser escapados (precedidos) por el carácter backslash:

\x corresponde al carácter especial **x**

- ¿Cómo encontrar el backslash? (Pista: También es un carácter especial)

Encontrar caracteres especiales

- ¿Cómo encontrar caracteres especiales?
- Deben ser escapados (precedidos) por el carácter backslash:

\x corresponde al carácter especial **x**

- ¿Cómo encontrar el backslash? (Pista: También es un carácter especial)

**** se corresponde con ****

Clases de caracteres

Clases de caracteres: Definición

- Clase de caracteres: un conjunto de caracteres
- Una clase de caracteres se define como un conjunto de signos entre corchetes, como **[aeoiuáéíóú]**

Clases de caracteres: Abreviaturas

- Existen formas abreviadas de representar clases de caracteres de uso frecuente:
  - Blancos: **\s** (incluye tabulaciones, espacios y saltos de línea)
  - Números: **\d**
  - Caracteres de palabra: **\w**
    - Nota: *\w* encuentra caracteres acentuados en muchas aplicaciones, pero no en todas las aplicaciones que soportan expresiones regulares.
      En Geany y notepad++ \w encuentra caracteres acentuados, en SublimeText no

Abreviatura negada de una clase de caracteres: El complemento de la clase

- La alternancia **mayúscula/minúscula** para la abreviatura de una clase de caracteres representa el **complemento** de la clase
- Dada una clase **\x**, **\X** es todo lo que no está en \x y vice-versa
- **\s** = blancos ; **\S** = no blancos
- **\w** = caracteres de palabra ;
  \W no caracteres de palabra
- **\d** = dígitos ; **\D** todo menos un dígito

Clases de caracteres negadas [^]

- Para negar una clase, escribir el carácter **^** como el símbolo inicial dentro de los corchetes:
  - **[aeiou]** Todas las vocales sin acentos
  - **[^aeiou]** Todo menos vocales sin acentos

Clases de caracteres negadas [^]

- Las abreviaturas de clase también pueden ser negadas con el símbolo **^**
- Da el mismo resultado que la alternancia entre mayúsculas y minúsculas (slide 38)
- [**^\d**] es igual a **\D** (todo salvo un número)
- [**^\s**] es igual a **\S** (todo salvo un blanco)

Otros caracteres importantes

Otros caracteres importantes

- **\t** tabulación
- **\n** salto de línea (ocurre al final de la línea)
- **\r** retorno de carro (a veces ocurre al final de la línea, por ejemplo en Windows, el final de línea se representa con **\r\n**)

Clases de caracteres que corresponden a cada abreviatura

- \w [A-Za-z0-9_]
- \W [^A-Za-z0-9_]
- \s [\t\r\n\v\f]
- \S [^ \t\r\n\v\f]
- \d

Clases de caracteres que corresponden a cada abreviatura

- \w [A-Za-z0-9_]
- \W [^A-Za-z0-9_]
- \s [\t\r\n\v\f]
- \S [^ \t\r\n\v\f]
- \d [0-9]
- \D

Clases de caracteres que corresponden a cada abreviatura

- \w [A-Za-z0-9_]
- \W [^A-Za-z0-9_]
- \s [\t\r\n\v\f]
- \S [^ \t\r\n\v\f]
- \d [0-9]
- \D [^0-9]

Comodín universal:
El punto

El punto corresponde a (casi) cualquier carácter

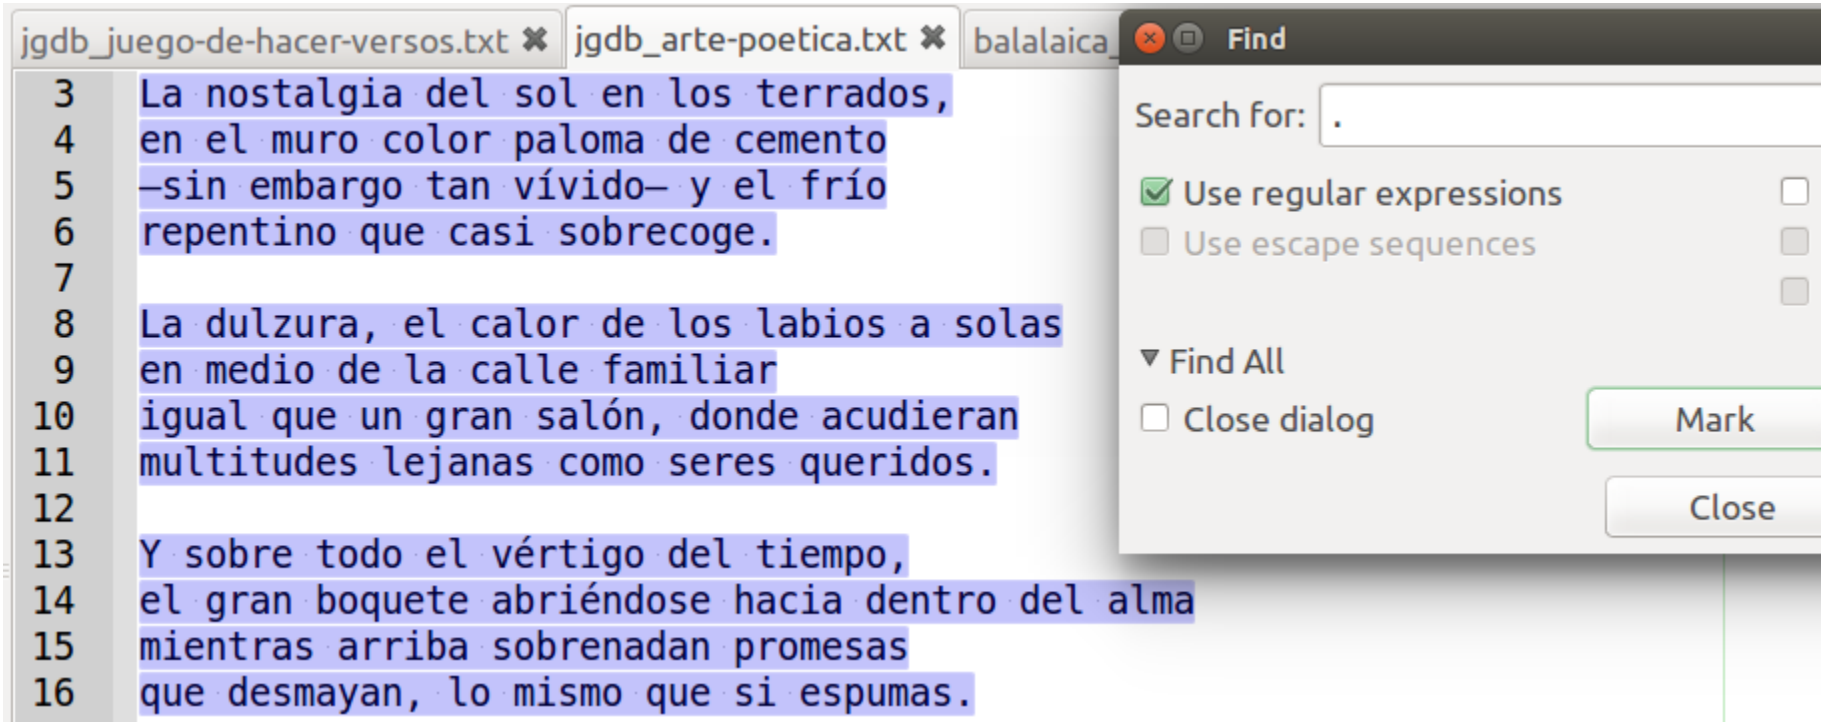

- Nota: El punto corresponde a cada uno de los caracteres separadamente.
- Con la función *Mark* en Geany, da la impresión de que cada línea es una correspondencia, pero cada carácter es un match separado (se puede verificar haciendo click en *Next*)
- En regex101.com se ve más claro que un punto = un carácter

El punto corresponde a (casi) cualquier carácter

¿Qué expresión correspondería a cada línea (La línea entera)?

El punto corresponde a (casi) cualquier carácter

¿Qué expresión correspondería a cada línea (La línea entera)?

.*

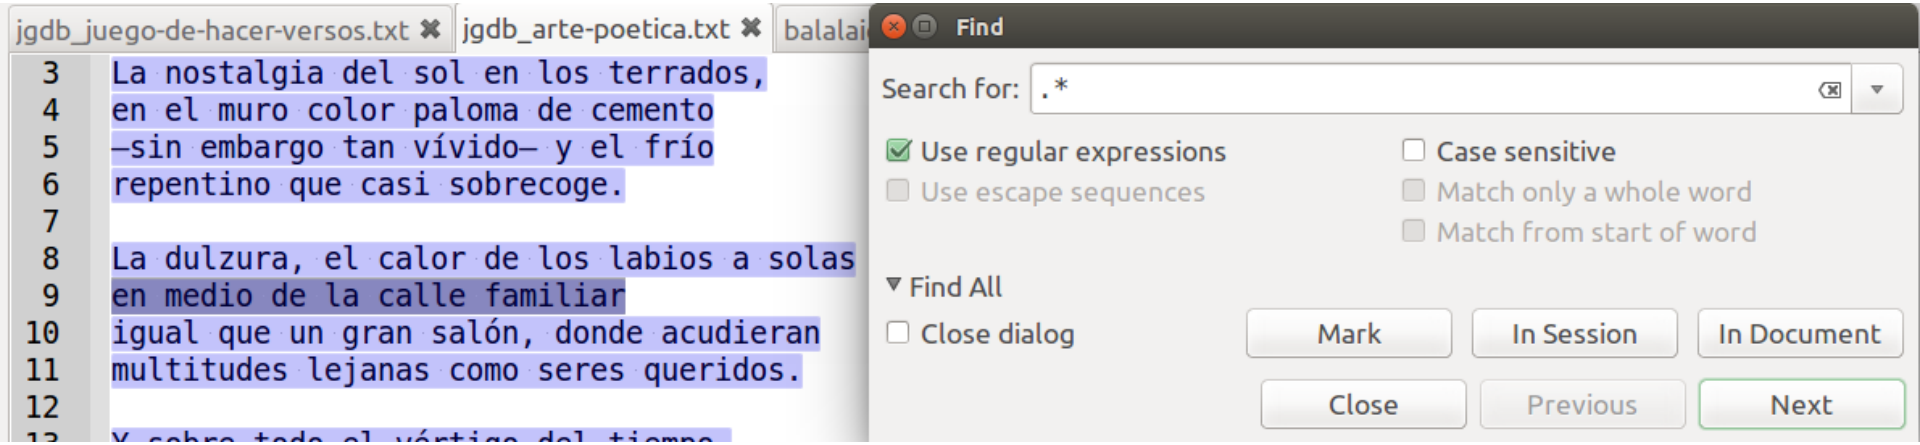

La sombra azul parece igual que para el punto solo, pero haciendo clic en *Next* se ve que ahora es cada LÍNEA lo que se destaca cada vez (no cada carácter)

Por defecto, las regex se evalúan línea a línea

¿Por qué *casi* cualquier carácter?

¿Qué expresión correspondería a cada línea (La línea entera)? `.*`

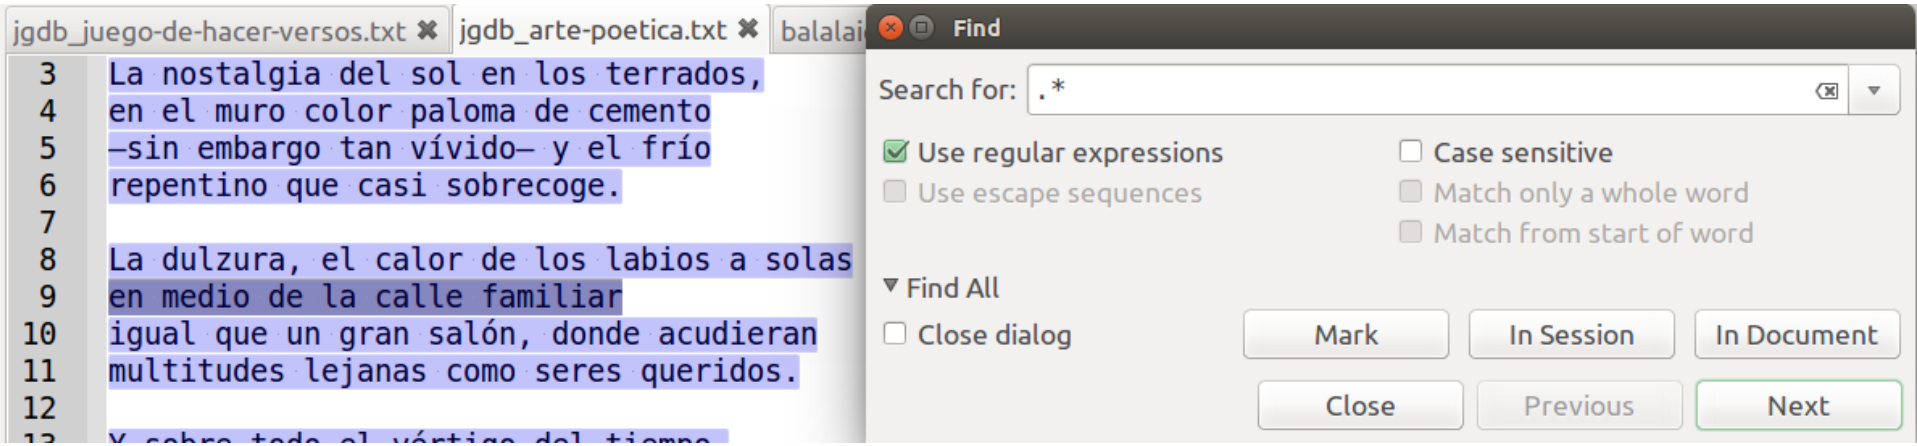

¿Por qué *casi* cualquier carácter?

¿Qué expresión correspondería a cada línea (La línea entera)? `.*`

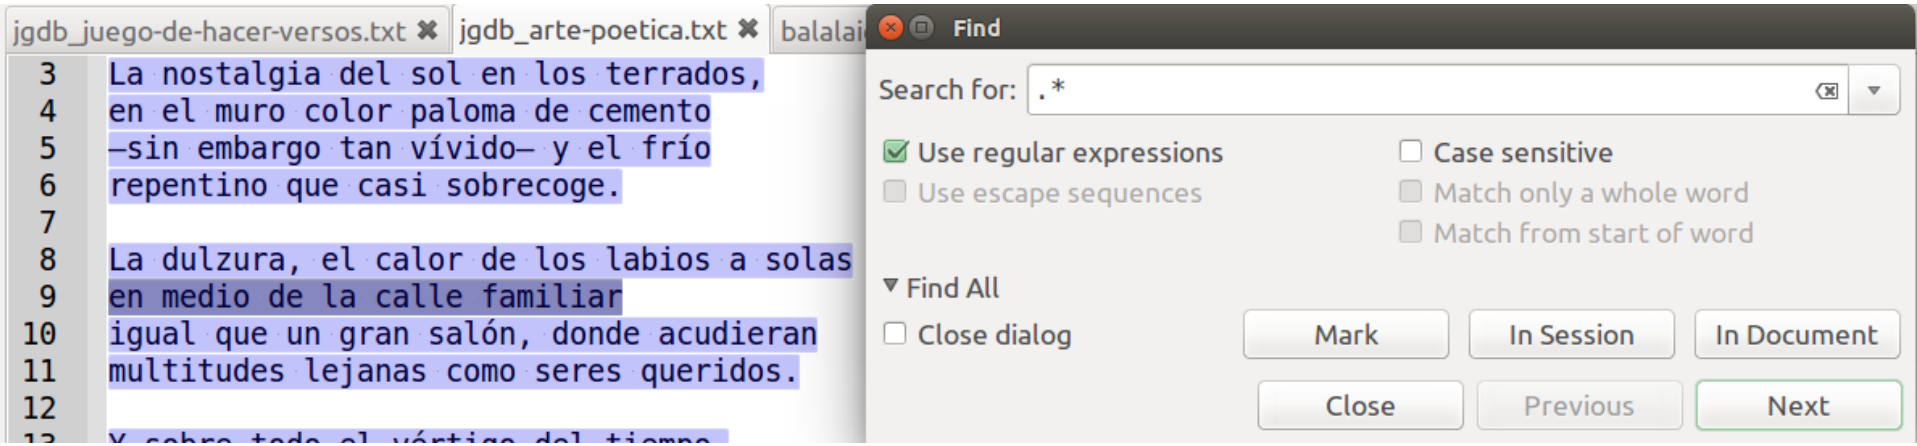

El punto no corresponde a los saltos de línea

Anclas (anchors) y fronteras de palabra

Anclas

- No corresponden a ningún carácter, sino a posiciones en un texto
- El patrón a buscar queda “anclado” a una posición
  - **^** principio de línea
  - **$** final de línea

Nota: Un símbolo, diferentes significados

- El signo **^** puede significar una de dos cosas en las regexes

Nota: Un símbolo, diferentes significados

- El signo **^** puede significar una de dos cosas en las regexes
  - Dentro de una clase de caracteres, niega la clase (*[^xyz]* = todo menos *xyz*, ver slide 39)
  - En los demás contextos, significa el principio de la línea
- Como en los lenguajes naturales, el contexto desambigua un signo

Fronteras de palabra

(1) **\b** Ancla para el principio o final de una palabra

(2) **\<** Ancla para el principio de una palabra

(3) **\>** Ancla para el final de una palabra

- No corresponden a un patrón, pero indican la posición donde debe ser encontrado el patrón, con respecto al principio/fin de las palabras
- (2) y (3) no están disponibles en todas las aplicaciones (Geany no los usa, pero Sublime Text y Notepad++ sí)

Fronteras de palabra

Correspondencias a principio o fin de palabra

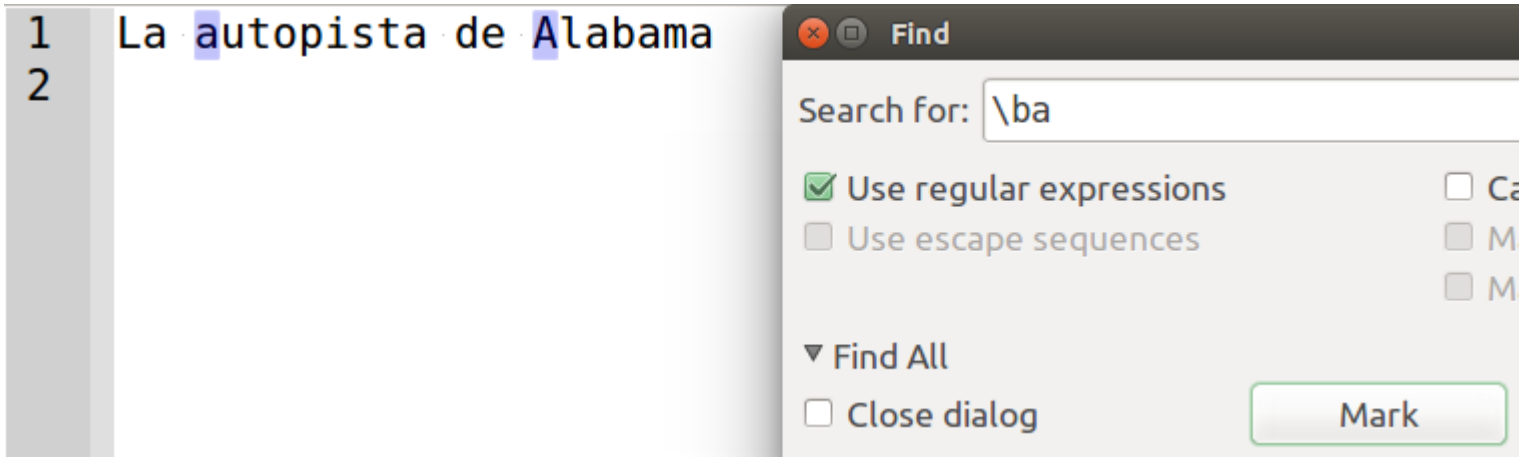

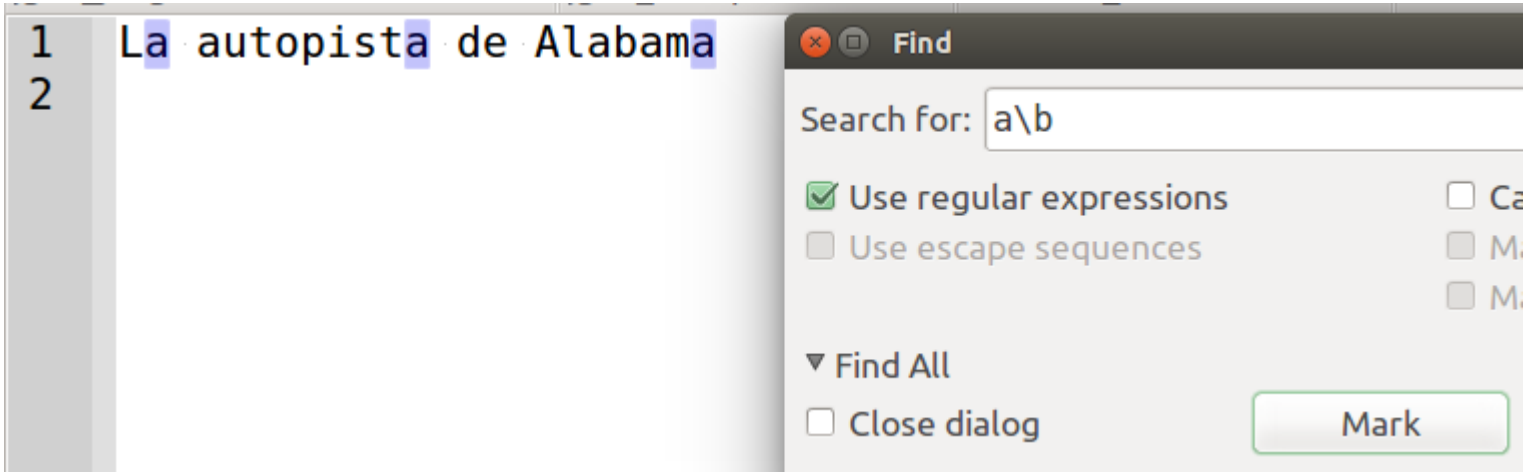

Alternancias

El carácter | (“pipe”) introduce una alternancia

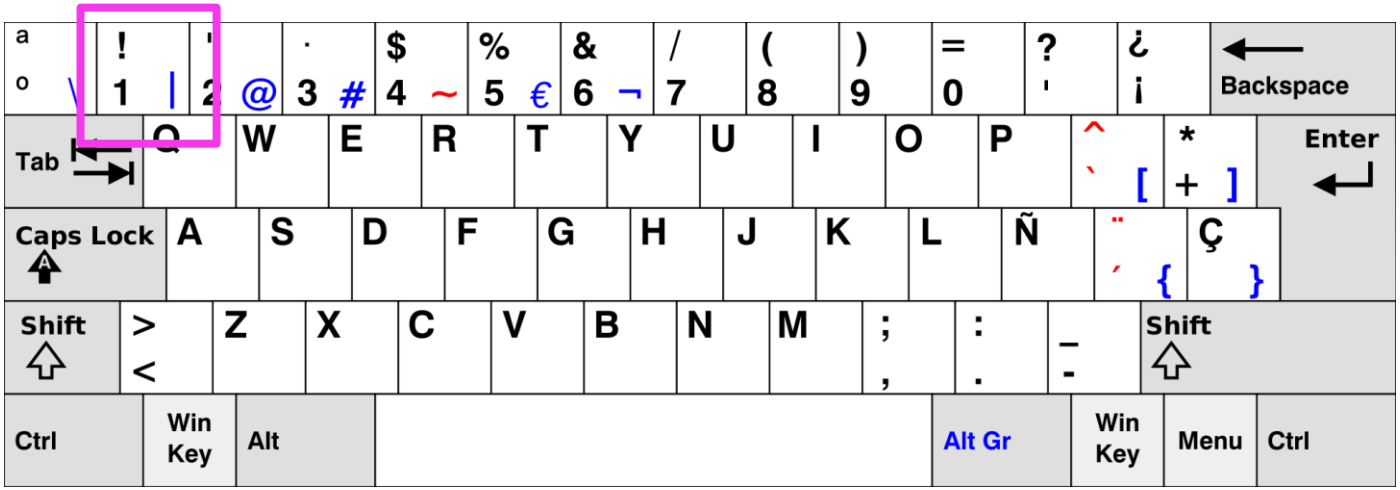

Teclado de España Alt Gr + 1

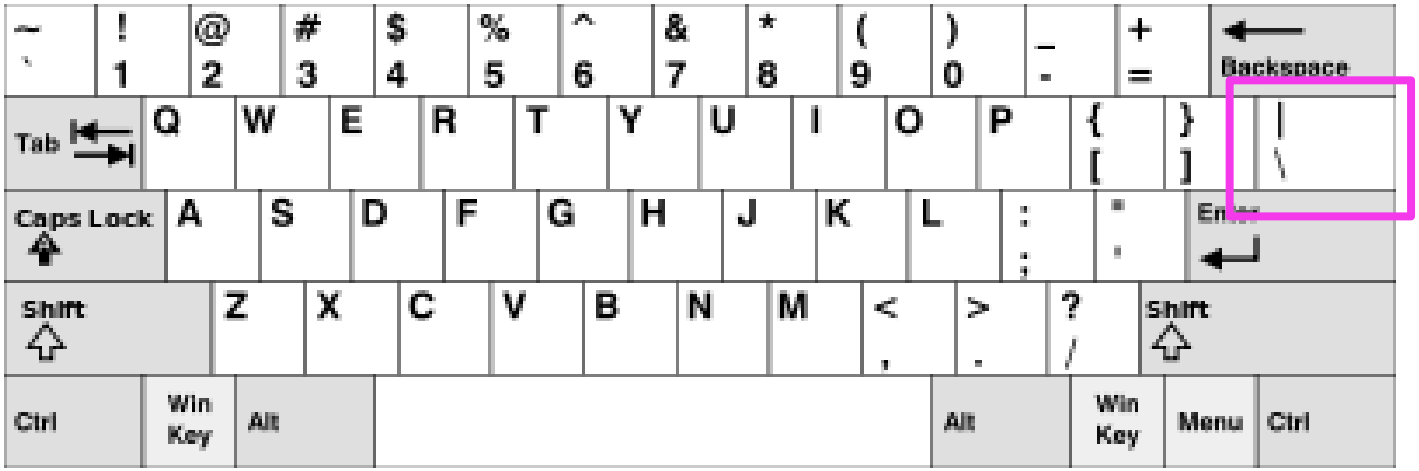

Teclado de USA

| Alternancia con “pipe”

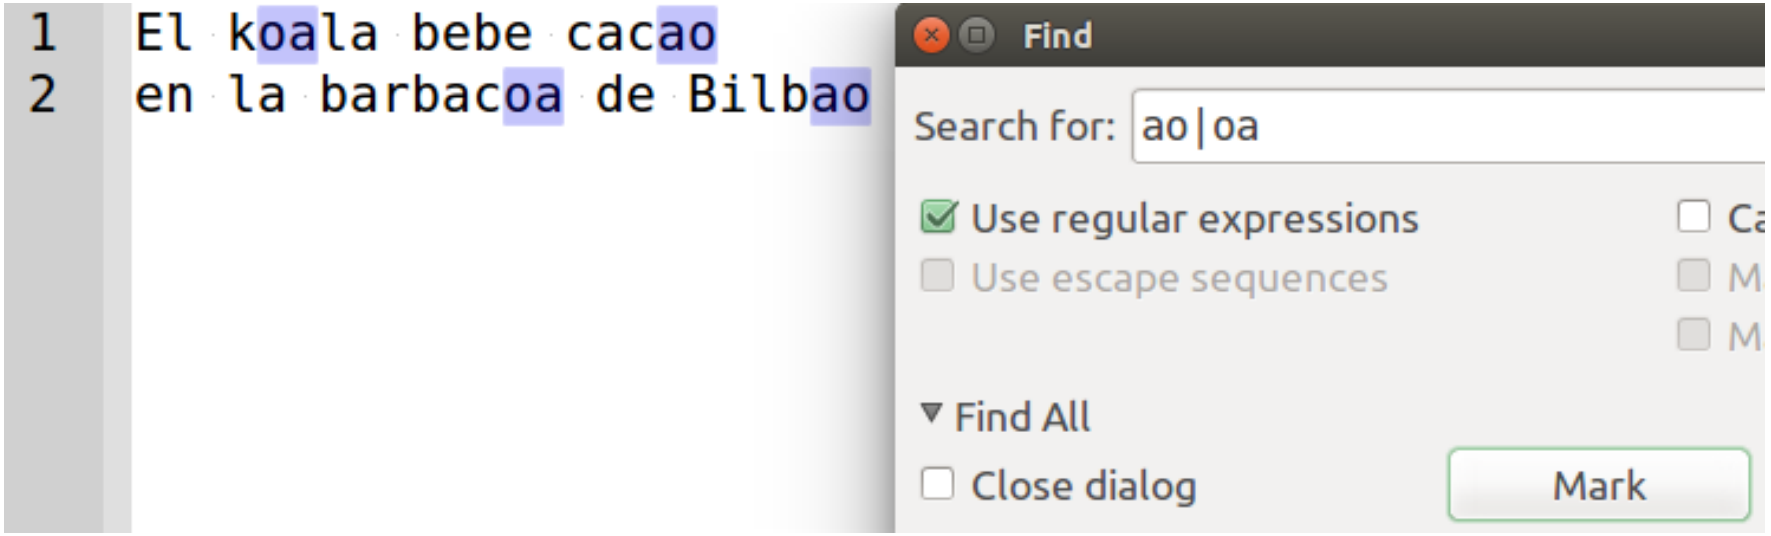

ao|oa corresponde a **ao** y **oa**

Grupos, Referencias y Sustituciones

() Grupos y referencias: Reemplazar texto

- Una regex entre ***()*** es un **grupo**
  - Usando un grupo, almacenamos en el grupo el texto que corresponde a la expresión
  - Normalmente hay un máximo de 9 grupos
- Para acceder al contenido de cada grupo, usamos una **referencia** de **\1** a **\9** (ver abajo)

- Nota: También existen grupos de **no captura**, definidos con **(?:)**
  - Definen el alcance de un operador, pero no almacenan contenido
  - Se usan cuando no necesitamos memorizar (almacenar) el texto que corresponde a un grupo

() Grupos y referencias: Sustituir texto

Ctrl + H

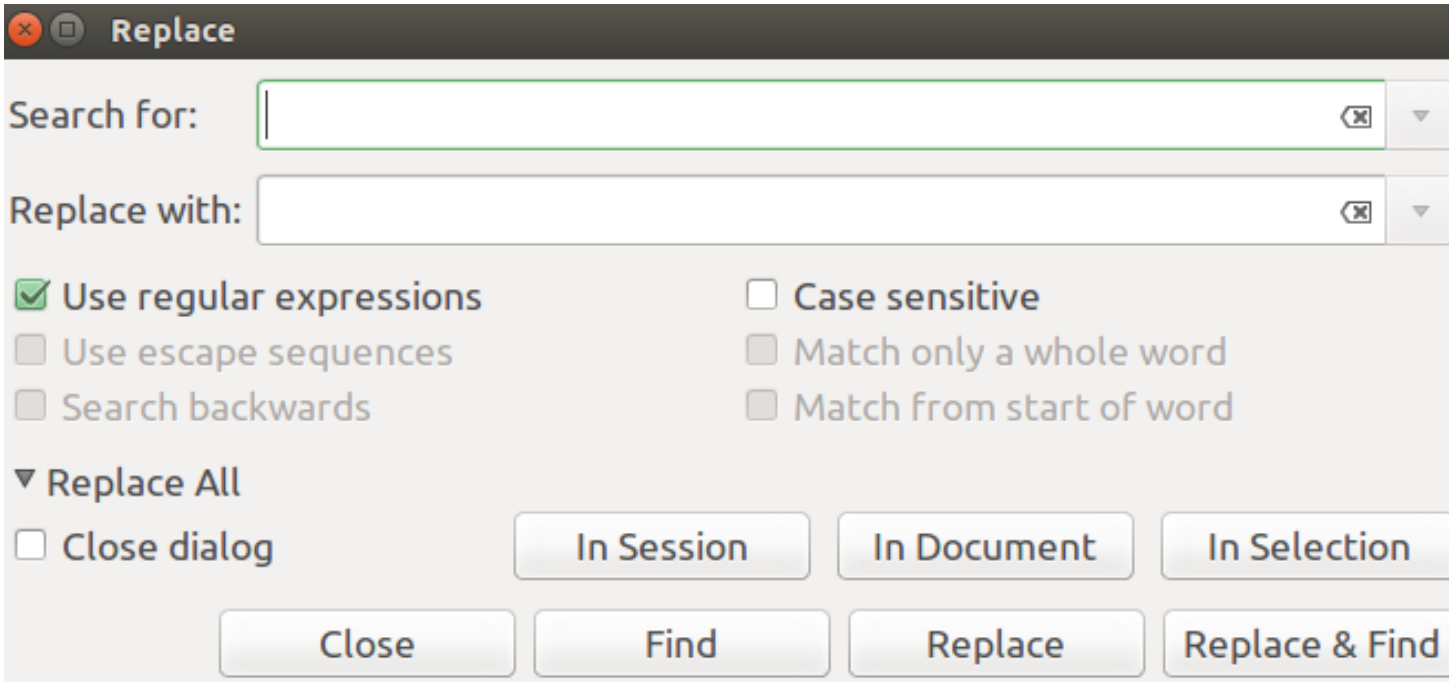

() Grupos y referencias: Sustituir texto

- Ejemplo
  - Cambiar una lista de nombres del formato **Nombre Apellido** al formato **Apellido, Nombre**
  - E.g. *John Smith* se sustituye por *Smith, John*

() Grupos y referencias: Sustituir texto

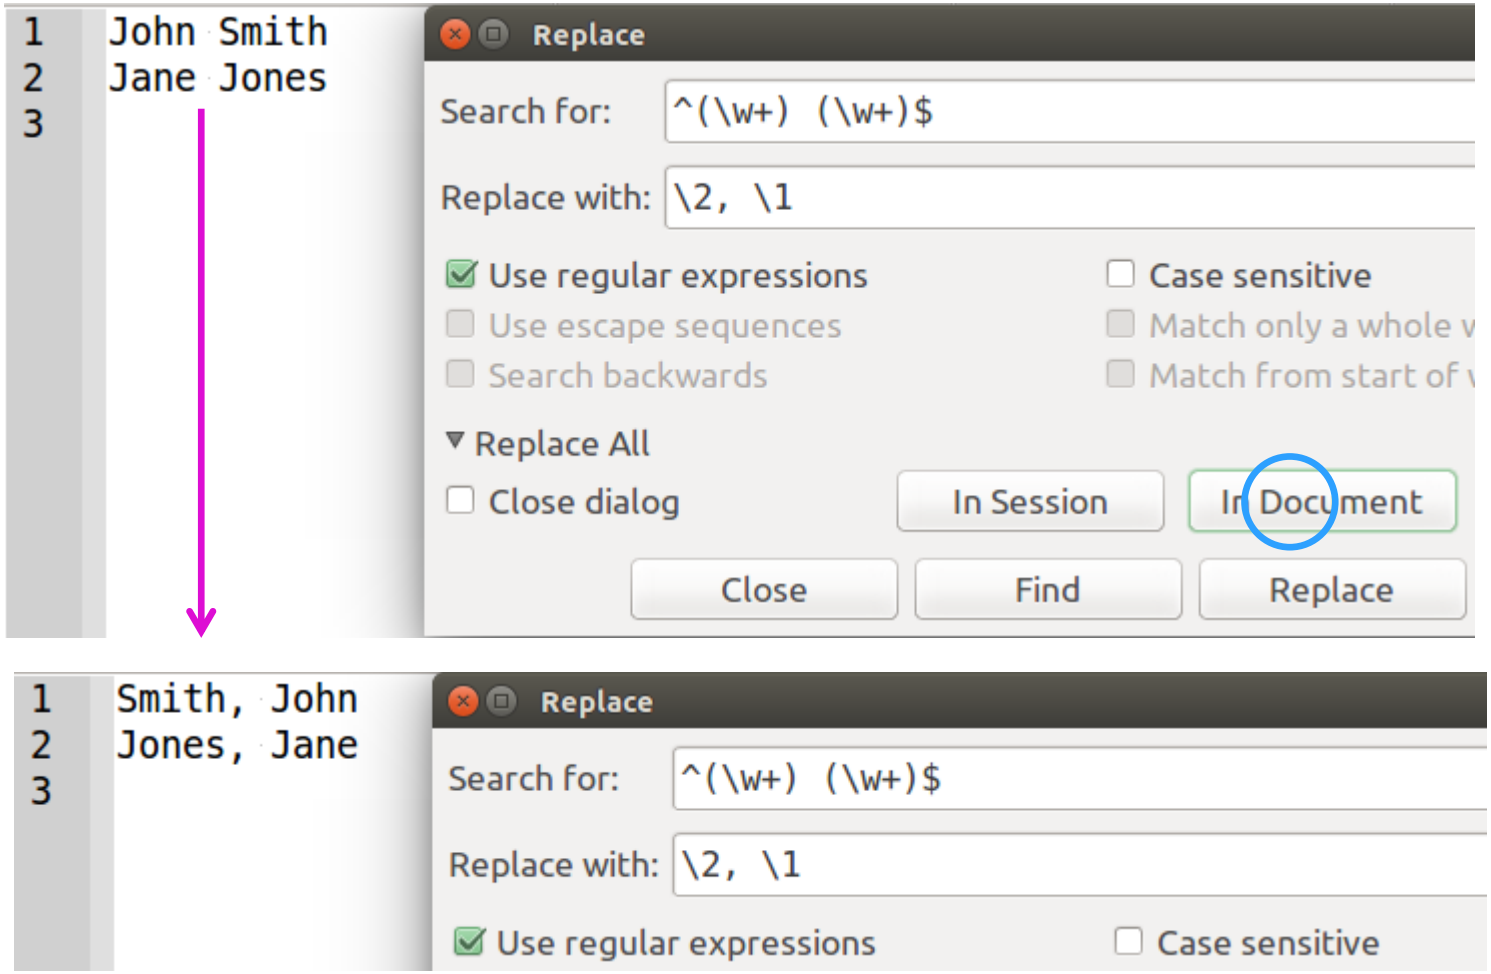

John Smith

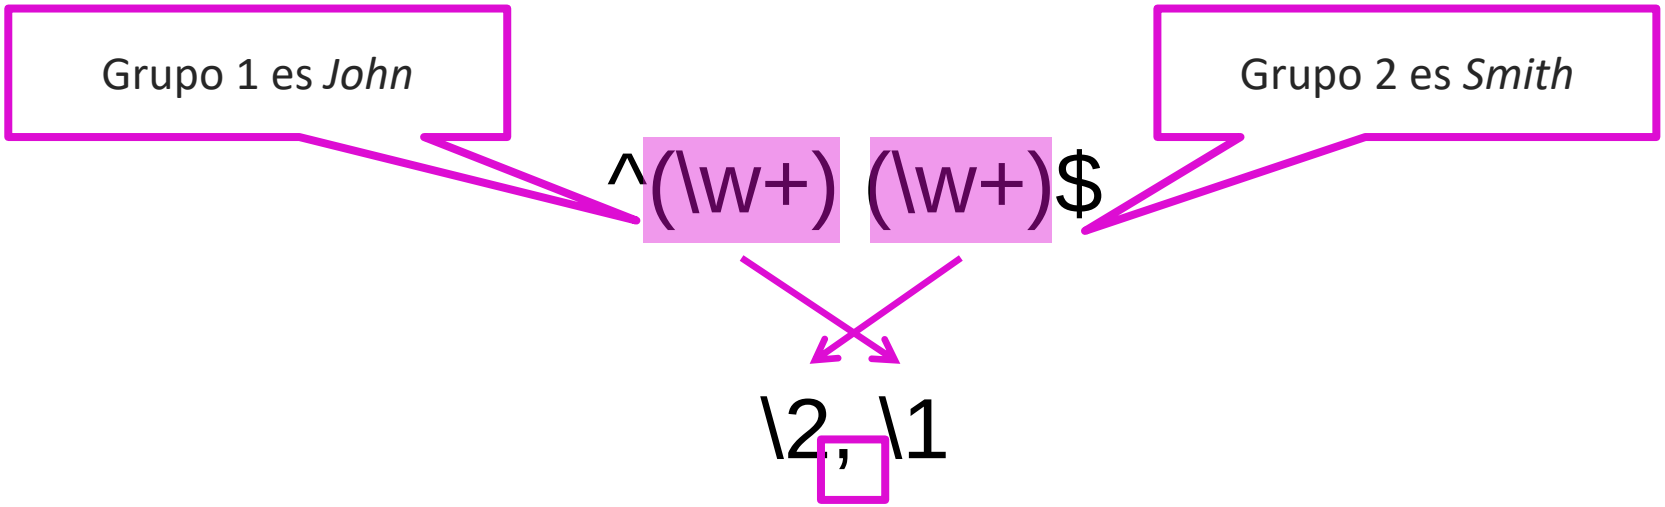

Smith, John

Punto de partida: **John Smith**

Objetivo: **Smith, John**

John Smith

^(\w+) (\w+)$

Punto de partida: **John Smith**

Objetivo: **Smith, John**

John Smith

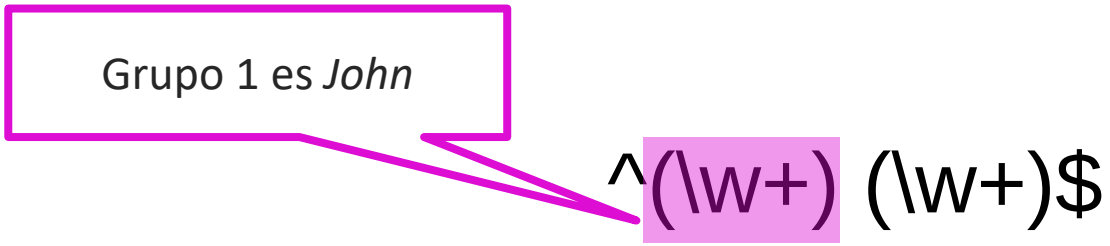

Punto de partida: **John Smith**

Objetivo: **Smith, John**

John Smith

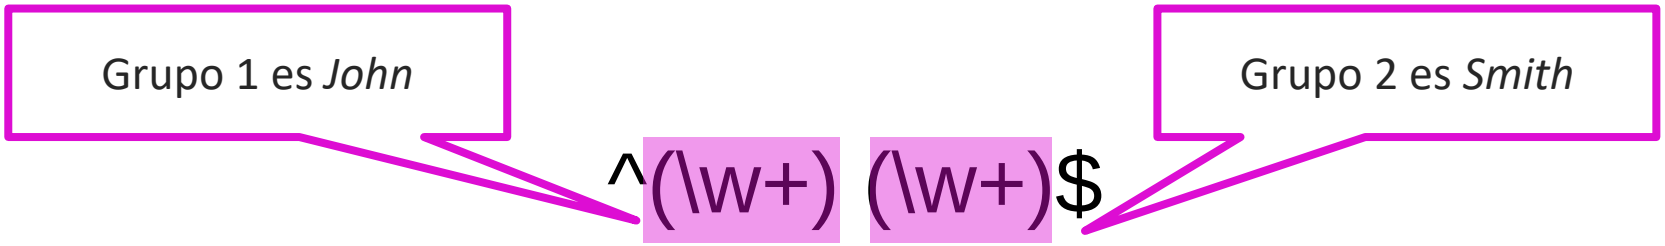

Punto de partida: **John Smith**

Objetivo: **Smith, John**

John Smith

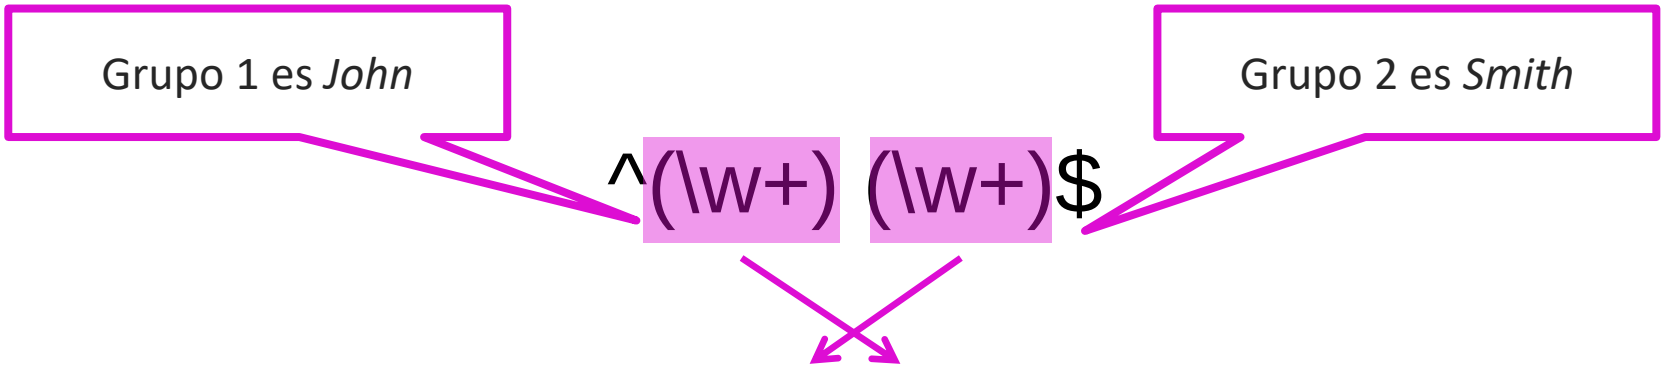

Punto de partida: **John Smith**

Objetivo: **Smith, John**

John Smith

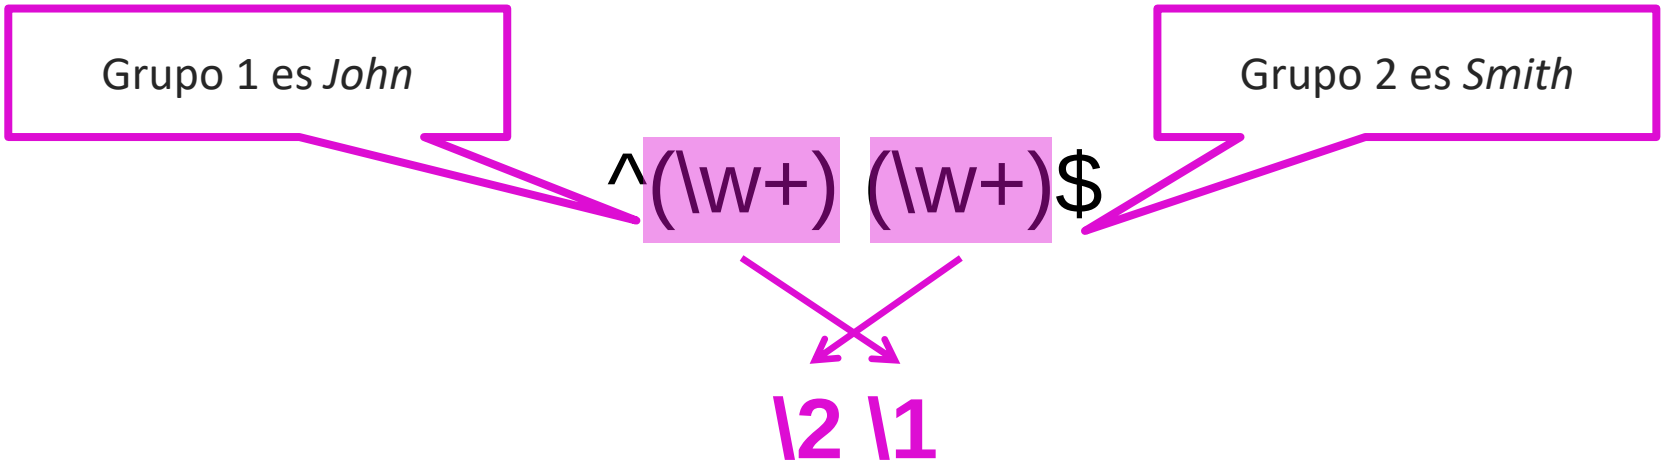

Punto de partida: **John Smith**

Objetivo: **Smith, John**

John Smith

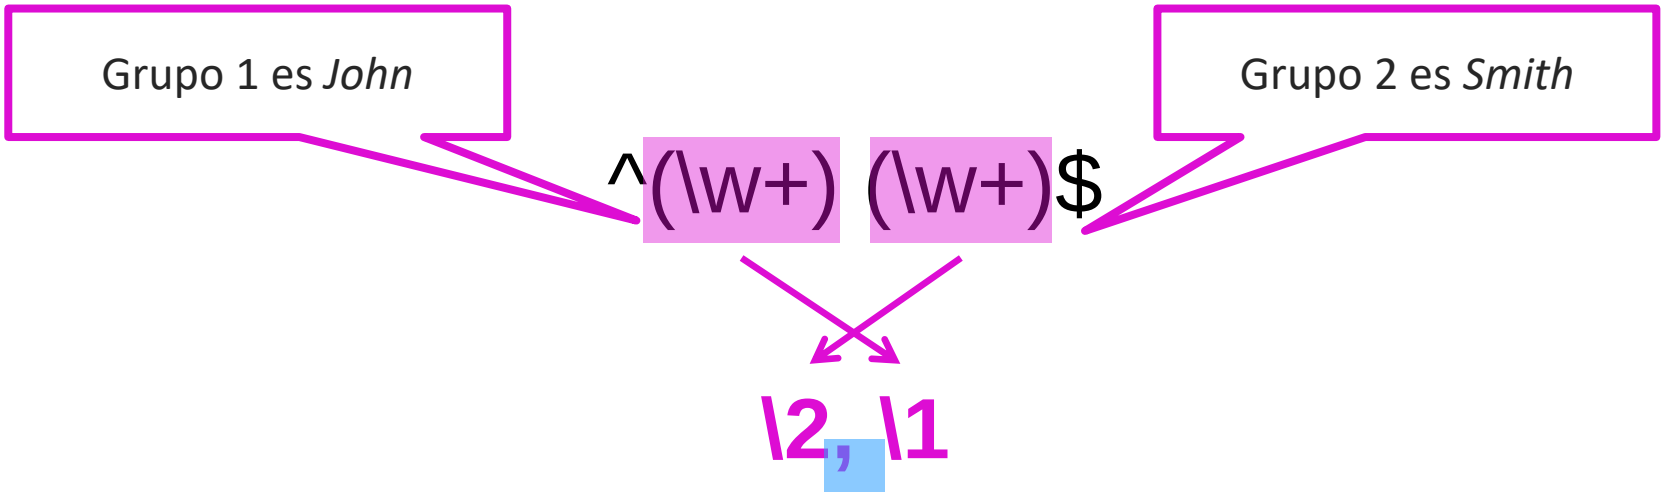

Punto de partida: **John Smith**

Objetivo: **Smith, John**

John Smith

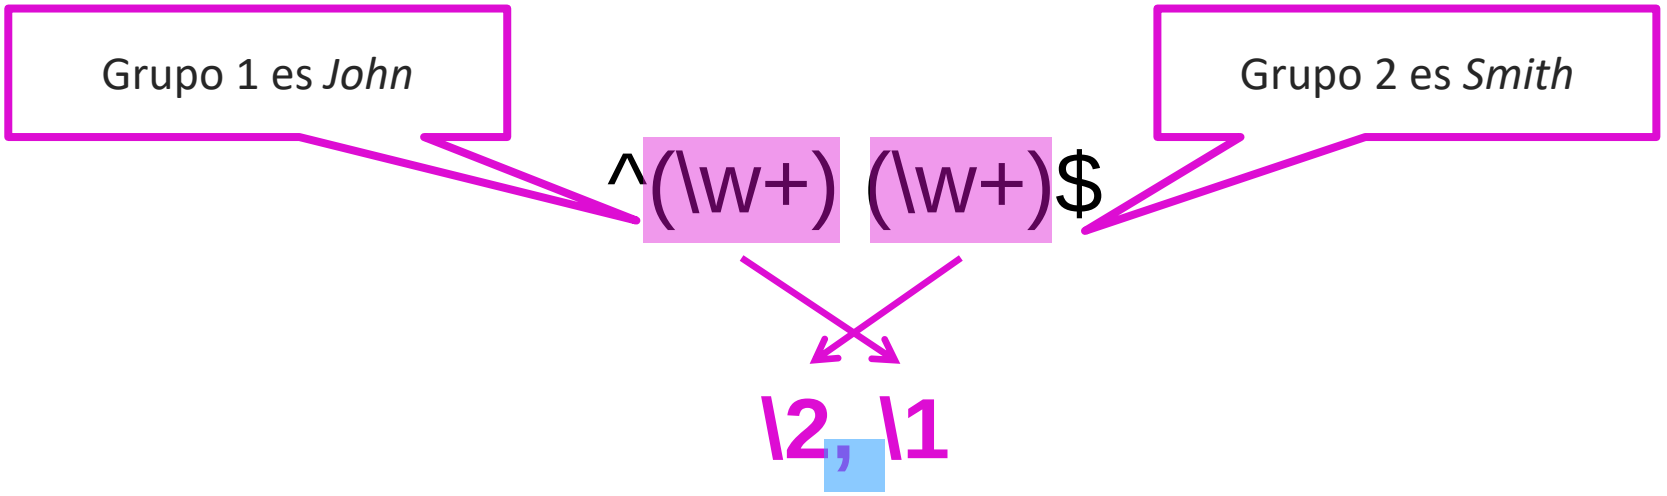

Smith, John

Información adicional

- Operadores de lookaround
  - lookahead positivo y negativo
    - *a* seguido/no seguido por *b*, **sin incluir *b* en el match**
    - `a(?=b)` `a(?!b)`
  - lookbehind positivo y negativo
    - `(?<=b)a` `(?<!b)a`
    - *a* precedido/no precedido por *b*, **sin incluir *b* en el match**
- Optimización
  - `a[^b]*b` es más rápido que `a.+?b` para buscar «*a* seguido de cualquier otro carácter (o nada) hasta la primera ocurrencia de *b*»

Lectura adicional

- http://www.regular-expressions.info/
- Friedl, J.E.F. *Mastering Regular Expressions*. O'Reilly.

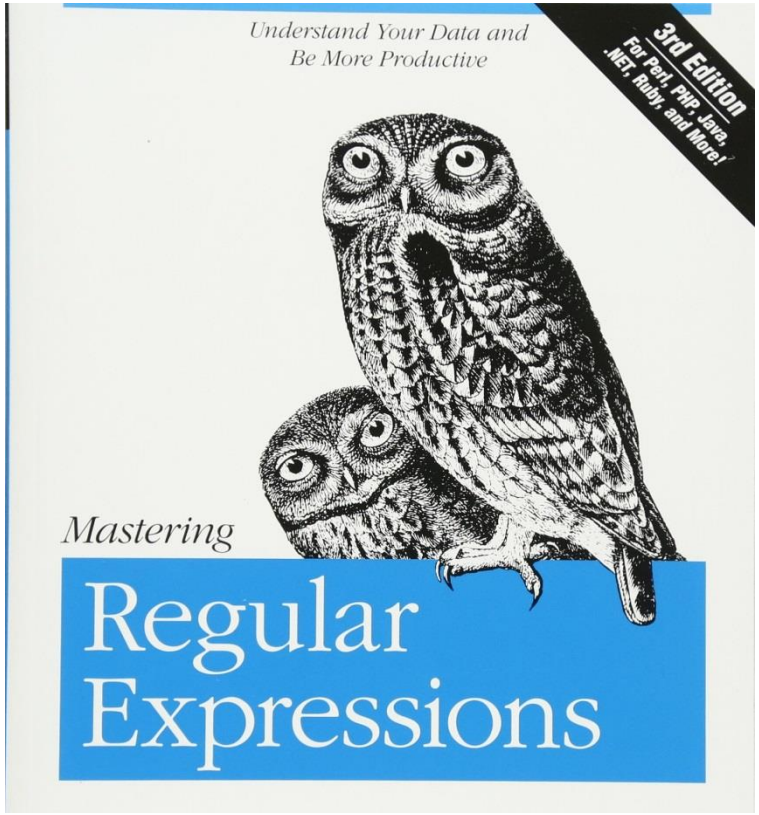

Ejercicios

- Se pueden probar las regex en un editor de texto, o en los sitios de la diapositiva 6
- Por ejemplo, regex101.com (diapositiva siguiente), da información sobre la secuencia que corresponde a cada grupo de captura en la regex

regex101.com

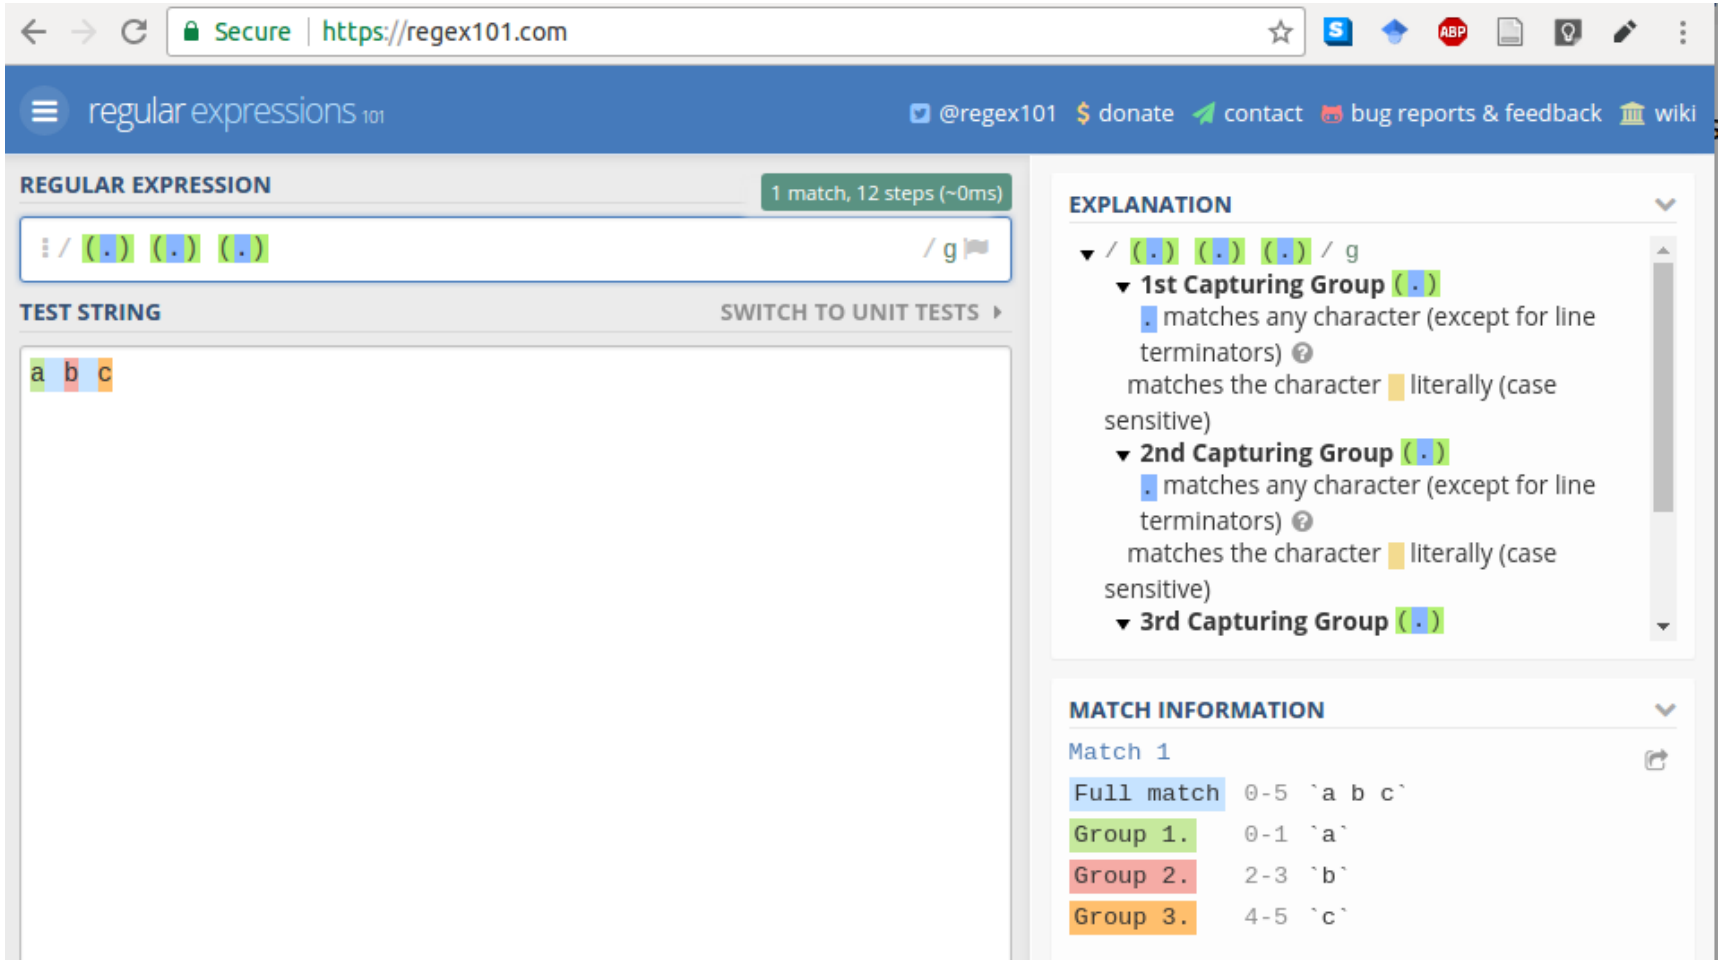

Pablo Ruiz Fabo
ruizfabo@unistra.fr